



### 저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

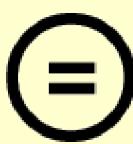
다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원 저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리와 책임은 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)



# 석사학위논문

# CNN 기반 공동주택 도배하자 검출 딥러닝 이미지 분류모델 구축에 관한 연구

# Development of a Deep Learning Model to Classify Images of Wallpaper Defects in Apartment Building by Introducing Convolutional Neural Network

# 전한라

한양대학교 공학대학원

2023년 2월

## 석사학위논문

# CNN 기반 공동주택 도배하자 검출 딥러닝 이미지 분류모델 구축에 관한 연구

Development of a Deep Learning Model to Classify  
Images of Wallpaper Defects in Apartment Building by  
Introducing Convolutional Neural Network

지도교수 김주형

이 논문을 공학 석사학위논문으로 제출합니다.

2023년 2월

한양대학교 공학대학원

건축공학전공

진한라

이 논문을 전 한 라의 석사학위논문으로 인준함

2023년 2월



한양대학교 공학대학원

# 목 차

목 차 .....	i
표 목 차 .....	iv
그림 목 차 .....	v
국문 초록 .....	vi
제 1 장 서 론 .....	1
1.1 연구의 배경 및 목적 .....	1
1.2 연구의 범위 및 방법 .....	2
제 2 장 공동주택 하자 및 관리 방법 .....	4
2.1 도배하자 .....	4
2.1.1 신축 공동주택 하자 .....	4
2.1.2 도배 하자의 원인 및 종류 .....	5
2.1.3 도배하자의 분류 .....	7
2.2 기존 도배하자 관리 업무 현황 및 프로세스 조사 .....	12
2.2.1 육안 조사의 한계 .....	12
2.2.2 공동주택 품질점검 프로세스 .....	13
2.2.3 아파트 하자 점검 업무 현황 .....	16
2.2.4 아파트 하자 점검업무의 한계 .....	17
2.3 기존 하자 관리 연구 고찰 .....	19
2.3.1 하자관리를 위한 시스템 개발 .....	19
2.3.2 하자 관리 업무 프로세스 개선 .....	21
2.3.3 고찰 결과 .....	23

2.4 컴퓨터 비전 분야의 이론 고찰 .....	24
2.4.1 컴퓨터 비전 .....	24
2.4.2 머신 러닝 .....	26
2.4.3 Classification .....	27
<b>제 3 장 컴퓨터 비전 기술을 활용한 하자 관리 제안 .....</b>	<b>30</b>
3.1 딥 러닝 .....	30
3.1.1 CNN .....	31
3.1.2 Resnet .....	33
3.2 CNN을 활용한 물체 인식법 .....	36
3.3 컴퓨터 비전 기술을 이용한 건설 분야 연구 동향 .....	38
3.3.1 구조물 손상 탐지 .....	38
3.3.2 물체 인식 딥러닝 알고리즘 실험의 비교 및 분석 .....	40
3.4 이론 및 기존 연구 고찰 결과 .....	42
<b>제 4 장 학습 데이터 .....</b>	<b>44</b>
4.1 학습 데이터 정의 .....	45
4.2 데이터 수집 .....	45
4.3 Resnet50 알고리즘을 이용한 모델 학습 .....	47
<b>제 5 장 모델 성능 검증 및 평가 .....</b>	<b>53</b>
5.1 평가 방법 .....	53
5.2 모델 성능 지표 .....	56
5.2.1 검증 결과 .....	58
5.3 이미지 예측 .....	58
5.3.1 검증 결과 .....	61

제 6 장 결론 .....	64
참 고 문 헌 .....	67
ABSTRACT .....	73



## 표 목 차

표 1. 도배하자 유형 및 원인/ 대책 .....	12
표 2. 건설 육안 품질점검 시 영향을 주인 요인 및 문제점 .....	13
표 3. 입주전 하자 관리 프로세스 .....	14
표 4. 아파트 점검자의 공종별 점검항목 .....	18
표 5. 하자 관리 시스템 개발 관련 연구 .....	20
표 6. 하자관리 업무 프로세스 개선 관련 연구 동향 .....	22
표 7. 학습 방식에 따른 머신러닝 알고리즘 분류 .....	26
표 8. KNN 알고리즘의 거리 측정의 방식 .....	29
표 9. CNN 학습 모델의 구조 .....	33
표 10. 모델별 균열 이미지 학습과 탐지 결과 .....	42
표 11. 전체 학습 데이터 목록 .....	47
표 12. 모델 학습을 위한 컴퓨터 환경 .....	48
표 13. 기계학습을 위한 Resnet50 모델 .....	49
표 14. Training Data, Validation Data .....	51
표 15. 모델학습을 위한 변수 설정값 .....	52
표 16. Precision, Recall, F1-Score, Support .....	57
표 17. 검증 결과 요약 .....	58
표 18. Data Set 예측 결과 .....	63
표 19. 시험1,2의 항목별 예측 순위 및 평균 정확도 .....	63

## 그 림 목 차

그림 1. 연구 진행 흐름도 .....	3
그림 2. 아파트 하자 분쟁 비율과 하자 유형별 입주자 불만족도 .....	5
그림 3-1. 이음부 접착 불량 .....	8
그림 3-2. 변색 및 곰팡이 .....	9
그림 3-3. 찢어짐 및 찍힘 현상 .....	10
그림 3-4. 도배 들뜸, 좌(정상) / 우(하자) .....	11
그림 3-5. 도배 터짐 현상 .....	11
그림 4. 건설회사의 하자보수 처리 절차 .....	15
그림 5. 기존 아파트 중간품질점검 프로세스 .....	16
그림 6. 컴퓨터 비전의 처리 과정 .....	25
그림 7. KNN 알고리즘 .....	28
그림 9. 딥러닝 학습모델을 이용한 처리 및 학습 과정 .....	30
그림 10. CNN Network 구조 .....	31
그림 11. 기존 CNN 학습모델(좌)과 Resnet(우)의 학습 원리 .....	34
그림 12-1. Identity Block(상), Convolution Block(하) .....	35
그림 12-2. Identity Block(상), Convolution Block(하) .....	35
그림 13. 딥러닝 모델을 이용한 물체 인식법 분류 .....	36
그림 14. 모델별 균열탐지 성능 비교용 데이터 .....	41
그림 15. 연구 방법 .....	44
그림 16. 학습 데이터의 4가지 범주 .....	45
그림 17-1. Augmentor 적용을 통한 데이터 증강 .....	46
그림 17-2. Data Augmentor 결과 .....	47
그림 18. Resnet50을 이용한 CNN Training .....	47
그림 19. Train/Validation 데이터 분할 과정 .....	49

그림 20. 학습 데이터 전처리 코드 .....	50
그림 21. 학습 방식 설정 코드 .....	52
그림 22. Confusion Matrix의 구성 .....	54
그림 23. Test Data Set .....	56
그림 24. 누적 학습에 따른 모델의 학습 정확도 .....	56
그림 25. 누적 학습에 따른 모델의 학습 손실율 .....	57
그림 26-1. 학습 전 이미지 예측 코드 .....	59
그림 26-2. 학습 후 이미지 예측 코드 .....	61
그림 27. 항목별 모델링 학습 후 이미지 인식 결과 .....	63



## 국 문 초 록

최근 재개발 및 재건축이 활발하게 진행되고 있고, 이에 따라 신축 공동주택의 입주예정자들은 과거에 비해 고품질 마감에 대한 요구 및 정부 기준에 맞는 마감 품질의 중요성이 대두되고 있다.

또한, 실내 마감 공사에 대한 하자 기준 세분화 및 식별 건수 또한 증가하는 추세이다. 현재 이러한 하자를 식별하기 위해 육안조사 등의 방식을 활용하였고, 이러한 조사는 신뢰성 부분에 큰 한계를 가지고 있는 방식이다. 현 추세는 골조에 관한 구조체의 균열 및 누수 관련 부분에 중점을 두고 하자 관련 선행 연구가 진행되었고, 내부 마감에 대한 하자 검측 연구는 전무한 상황이다. 따라서, 신뢰성 높은 하자 식별을 위해 기존 하자 검측 및 유지보수 업무 프로세스를 분석하고 이를 기초로 CNN 알고리즘을 활용해 신뢰성 높은 마감하자 검측 모델 구축을 위한 연구를 진행할 필요가 있다.

그리하여 본 논문에서는 마감하자 중 발생 빈도수가 높은 도배하자 식별 모델 구축에 관한 연구를 진행할 예정이다. 이를 위해 우선 신축 현장에서 직접 도배하자 관련 이미지를 수집한 후 데이터의 다양성 및 정확도 확보를 위해 Augmentor 적용을 통한 데이터 증강을 실시했고, 수집된 데이터를 기초로 Resnet50을 도배하자 4가지 분류 기준에 맞게 훈련 및 평가 데이터 셋으로 나누어 학습을 실시했고, 또한 구축한 시스템 모델의 적합성을 오차행렬, F-Score, Accuracy 등을 활용해 판정했다. 본 연구의 결과는 기존 육안검측 방안보다 기계 학습 방법의 효율성 및 신뢰성을 나타내고 있다.

추후 Multi-Label Classification을 기반으로 학습 모델을 구축해 이미지 데이터 내 다양한 하자를 동시에 측정하기 위한 연구를 진행할 필요가 있다.

# 제 1 장 서 론

## 1.1 연구의 배경 및 목적

최근 신축 공동주택 입주 예정자들은 고품질 마감에 대한 요구와 입주자들 간의 전문화 된 정보 공유 등을 통하여 아파트의 품질 및 하자 등과 관련된 입주자의 민원은 증가하고 있는 추세이다. 이에 따른 공동주택 하자 중 입주민이 일상생활이 주되게 이뤄지는 개인공간에 대한 부분에서 하자를 가장 쉽게 식별할 수 있어 실내마감 공사 부분에 대하여 외부에 비해 상대적으로 많은 수의 하자 접수가 발생하고 있다. 이러한 공동주택의 하자는 최근까지 빈번하게 발생하고 있다. 또한 하자 소송으로 이어지는 등 사회 문제로 대두되고 있다. 현 정부 들어 아파트 공급 물량은 예년 평균대비 전국, 수도권, 서울 각각 24.2%, 25.5%, 9.7% 늘어나 공급 됐으며, 특히 선호도가 높은 아파트의 경우 근 5년간 전국 기준으로 연평균 39만 가구 이상 공급되었다. 공급된 아파트에 대한 하자 갈등은 더욱 많아질 것으로 예상된다. 아파트 약 8개 단지를 대상으로 한 하자 발생 건수 및 하자 유형별 조사에 따르면, 전체 하자 발생 비율 중 도배하자의 경우 20%로 15개의 공사 중 가장 발생 비율이 높게 집계되었음에 따라 핵심적인 하자 문제로 식별됐다. 즉 도배하자의 효율적인 품질관리 방안을 연구할 필요성이 있음을 역설했다. 게다가, 2020년 국토교통부에서 발표한 '공동주택 하자의 조사, 보수비용 산정 및 하자판정기준' 개정안에 따르면 기존 하자 항목을 44개로 확대하였다. 이에 따라, 기존 하자로 인정되지 않던 도배 불량 항목이 추가 됐다. 즉 세분화 된 도배하자 항목이 신설됨에 따라 신축공사의 경우 마감공사에 대한 품질관리의 필요성이 대두 되었다. 그러나 공동주택 하자 관리방안에 대한 많은 연구가 진행되었으나 주로, 각 공

종별 하자 발생 원인과 하자 저감책을 제시하는 것에 집중되고 있다. 그러나 공동주택 신축공사는 다양한 공종의 결합으로 이루어지는 특성이 있기에 하자를 완전히 방지하는 것은 불가능하다. 즉 근본적인 하자의 원인을 통해 개선하는 것보다 실질적으로 하자를 신속 정확하게 찾는 것이 우선시 되어야 한다.

하지만, 현업에서 이루어지는 하자 평가는 대부분 점검자의 육안 조사에 의존한다. 점검자의 신체적인 부분에 의존하는 조사이기 때문에 이에 따른 오류의 범위는 30% 내외로 집계되고 점검자 개인별로 결과에 차이가 발생할 가능성도 있다. 또한, 시공사의 품질 향상 노력에도 불구하고 공사 완료 시점에는 인원 부족, 공기 부족, 품질관리 방안 한계 등으로 인해 체계적인 품질 관리가 이뤄지지 않고 있다. 최근에는 시설물 하자 검출에 대한 다양한 딥러닝 기술 중 영상 인식 및 분류에 특화된 딥러닝 알고리즘을 적용한 연구가 진행되고 있다.

## 1.2 연구의 범위 및 방법

본 연구는 기존 공동주택 하자 점검 한계를 극복하고 점검의 정확성과 효율성을 향상을 위하여 이미지 학습을 기반으로 머신 러닝을 활용해 이미지 알고리즘 기반 유지보수 및 하자 검출 자동화 모델을 개발하고, 이를 활용하여 본 연구에선 제안한 체계의 개선사항을 검증하고자 한다. 기존 하자에 관련된 연구는 골조에 관한 구조체의 균열 및 누수 관련 부분에 중점을 두고 있으며, 본 연구에 관한 내부 마감 공사에 대한 하자 검출 프로세스에 대한 연구는 전무한 상황이다. 따라서, 본 연구는 기존 하자 검출 및 유지보수 업무 프로세스를 분석하여 이를 기초로 CNN 알고리즘을 활용한 도배 관련 하자 검출 모델을 구축한다.

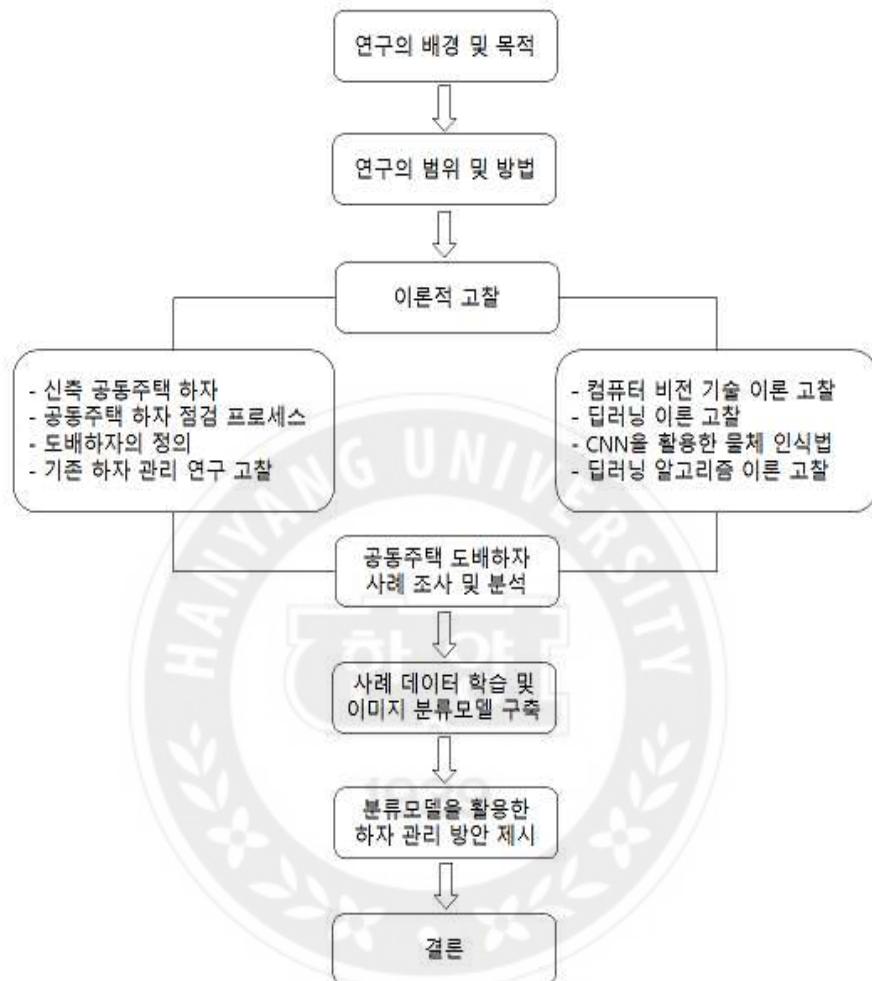


그림1. 연구 진행 흐름도

## 제 2 장 공동주택 하자 및 관리 방법

본 장에서는 문헌 연구를 기초로 도배 하자의 정의, 기존 하자 검출 및 관리에 관한 기존의 프로세스를 조사 및 분석하여 본 연구와의 연계성과 차별성을 분석하여 연구의 필요성을 제시한다. 또한, 공동주택 하자 검출에 적용되는 머신러닝 기술을 이론적으로 고찰한다.

### 2.1 도배하자

본 절에서는 공동주택 하자의 개념을 문헌 연구를 기초해 정의하고, 그 중 도배 하자의 원인과 종류, 발생 건수를 분석하여, 하자 검출 프로세스 구성의 필요성이 높은 공정인지 분석하고자 한다.

#### 2.1.1 신축 공동주택 하자

하자는 흔, 또는 결함으로 요약할 수 있으며, 주로 법률 또는 당사자가 예상하는 정상적인 상태를 충족하지 못하는 경우 쓰이는 말로써 기본적으로 불완전을 말하는 법률 용어이다. 건설공사에 대한 제작자의 측의 책임에 의해 생긴 결함 혹은 계약과의 차이로 법률상으로는 당사자가 예상하는 것이 존재하지 않은 경우를 의미한다.

즉 일반적인 하자의 개념은 거래 행위에 대상이 되는 물건이 관념 상 가지고 있는 표준품질 또는 성능 기준에 준해서 판단할 경우 결함이 인정되는 경우 즉 결함을 일컫는다.

주택법시행령에서 명시하는 공동주택 하자는 '공사상의 잘못으로 인한 균열, 벌어짐, 비틀림, 침하, 파손, 붕괴, 누수, 누출, 작동 또는 기능불량, 부착 또는 접지 불량 및 결선 불량 등으로 건축물 또는 시설물 등의 기능상, 미관상 또는 안정상 지장을 초래할 정도의 것을 의미한다. 공동주택 하자 위험도 평가에 관한 연구 따르면, 공동주택의 5년 내 하자 분쟁 발생 원인 중 마감공사가 36%로 가장 높은 비중을 차지한다. 마감공사는 총 미장공사, 방수공사, 목공사, 내장공사, 도배공사, 타일공사 등으로 나누어지고, 도배공사가 이 중 가장 높은 하자 발생 건수를 나타내고 있다. 또한, 입주자의 마감공사 불만족에 의한 하자 접수 비율도 가장 높은 비율을 나타내고 있다.

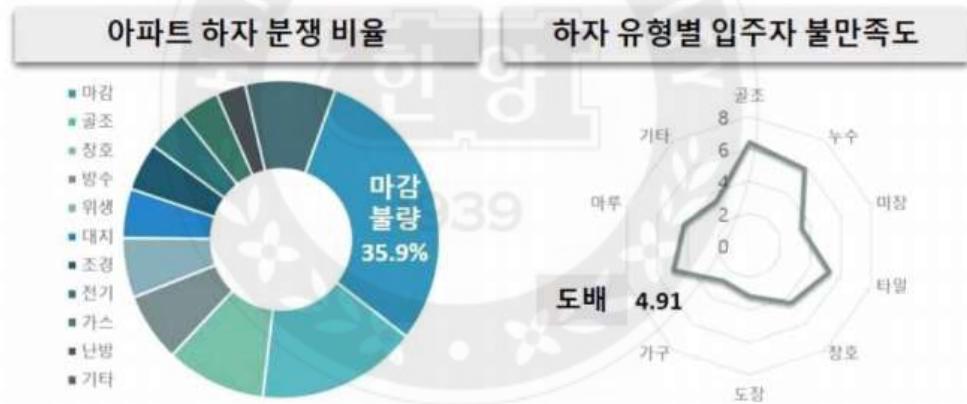


그림 2. 아파트 하자 분쟁 비율과 하자 유형별 입주자 불만족도, 강태준(2015)

### 2.1.2 도배 하자의 원인 및 종류

송광(2013)은 국내 건설 현장 5개의 현장의 도배공사 3,075세대의 하자

건수 1,893건에 대하여 평형대별 하자의 장소와 종류로 구분하여 하자율을 조사했다. 그 결과, 공사 하자의 원인은 자재 및 작업자에 의한 하자, 타공종의 작업자에 의한 하자, 가구 배치 등 후속 공정에 따른 하자로 나눌 수 있다. 각 원인별 하자에 대한 세부 사항은 다음과 같다.

### 1) 자재 및 작업자에 의한 하자

자재 자체의 결함이 있는 자재를 사용하거나, 작업자의 기술력이 부족하거나 등으로 발생하는 하자 종류이다. 이 경우, 크게 자재 자체가 파손 및 오염되거나 도배지를 붙이는 과정에서 부착이 불량하여 도배지가 울거나, 또는 현상이 생기며, 세부적인 사항은 다음과 같다.

- ① 자재 이색 하자
- ② 오염하자
- ③ 이음 불량 및 갈라짐
- ④ 도배지 울음

### 2) 후속 공종에 의한 하자

후속 작업자에 의한 하자는 단순 후속 작업자의 실수 또는 부실로 하자가 발생하는 경우와 공정관리 부실로 인한 역공정 시공으로 추가적인 하자가 발생한다. 이 경우 대부분 도배지가 스크래치, 찢김, 찍힘이 발생하며, 그에 대한 세부 사항은 다음과 같다.

- ① 찍힘 및 스크래치
- ② 타 공정에 의한 하자
- ③ 오염 및 훼손

### 3) 외부적 요인에 의한 하자

협소한 장소에서 도배를 하거나 창호 및 현관 등 외부환경에 의해서 영향을 받을 수 있는 장소에 시공한 면에 대해서 발생하는 하자를 말한다. 주로 습기, 화학물질과의 접촉으로 인해 도배 자재의 성능 저하, 변형 등이 발생한다. 그에 대한 내용은 다음과 같다.

- ① 곰팡이 및 결로하자
- ② 들뜸, 코너수축에 의한 하자
- ③ 천정, 커튼박스, 아트월 하자

#### 2.1.3 도배하자의 분류

이전에서 언급 한 바와 같이 도배하자는 현장의 환경과 작업자들 및 공정 진행상태 등 다양한 원인으로 발생할 수 있는 복합 하자이다. 보통 하자의 종류를 정의하고 정리하는데 중점을 두는 방식으로 진행되는 부분을 개선하기 위해 도배 하자를 분류 및 범주화 하여 본 연구의 목적인 도배 하자를 검증하고 관리하는 프로그램을 구성하기 위해 전체적인 하자를 큰 범주화로 분류할 예정이다.

도배하자는 크게 3가지의 범주로 나누어진다. 이음부 접착불량, 변색 및 곰팡이 발생, 찢어짐 및 찢김으로 나누었다. 앞서 말한 하자는 이전부터 시공상의 결함으로 인정 되어왔다. 하지만 최근 국토교통부에서 발표한 '공동주택 하자의 조사, 보수비용 산정 및 하자 판정기준' 개정안에 따르면, 이전 도배하자 유형 중 시공상 결함으로 판단되지 않은 도배지 처짐, 터짐 현상

을 판정 기준에 추가하였다.

### ① 이음부 접착 불량

이음부 접착 불량은 도배지를 선시공 한 부분에 이어서 시공하는 경우 주로 발생한다. 도배지의 조인트 부분이 뜨거나 틈새가 발생하는 특징이 있다. 작업자의 품질교육 및 숙련도가 미흡하거나 과도하게 밀착하여 시공하는 경우 발생하며, 자재 검수가 미흡하여 자재의 문제가 있는 경우 발생 하는 경우도 있다. 이러한 하자유형을 방지하기 위해서는 작업 간 풀칠을 충분히 하고, 적절한 자재를 사용하거나, 도배지 절단 및 끝단 부위 풀먹임 등 정밀시공 하는 방안이 있다.



그림 3-1. 이음부 접착 불량

## ② 변색 및 곰팡이 발생

곰팡이의 경우 벽체 및 바닥의 모르타르가 건조 되기 이전 작업을 한 경우, 벽 자체가 수분에 취약한 상태에서 곰팡이가 발생하기 쉬우며, 작업자나 외부적인 상황에 의해서 습기의 영향을 받는 경우도 발생할 수 있다. 변색의 경우 시공면의 상태가 불량하여 그로 인해 영향을 받거나, 마감재의 상태로 인해 변색이 일어나기도 한다. 또한, 초배지 생략 및 자재가 불량한 경우와 같이 작업자에 미숙련도에 의해서도 변색이 발생하기도 한다. 이러한 하자를 방지하기 위해선 시공 전 다른 공정의 상태를 면밀하게 확인하고, 습기 및 누수 등 외부적인 환경요소를 관리한 상황에서 시공이 진행 되어야한다.



그림 3-2. 변색 및 곰팡이

## ③ 찢어짐 및 찍힘 현상

곰팡이의 경우 벽체 및 바닥의 모르타르가 건조 되기 이전 작업을 한 경우,

벽 자체가 수분에 취약한 상태에서 곰팡이가 발생하기 쉬우며, 작업자나 외부적인 상황에 의해서 습기의 영향을 받는 경우도 발생할 수 있다.

변색의 경우 시공면의 상태가 불량하여 그로 인해 영향을 받거나, 마감재의 상태로 인해 변색이 일어나기도 한다. 또한, 초배지 생략 및 자재가 불량한 경우와 같이 작업자에 미숙련도에 의해서도 변색이 발생하기도 한다. 이러한 하자를 방지하기 위해선 시공 전 다른 공정의 상태를 면밀하게 확인하고, 습기 및 누수 등 외부적인 환경요소를 관리한 상황에서 시공이 진행 되어야 한다.



그림 3-3. 찢어짐 및 찍힘 현상

#### ④ 도배 들뜸

들뜸의 경우 주로 환경적인 요인과 현장 기능공의 작업 시공능력 미숙으로 주로 발생한다. 주로 동절기 공사를 진행하는 등 환경적인 요소에 영향을 받으며, 기능공이 현장 작업 간 바탕 상태가 불량한 경우, 초배지 접착

불량 등에 의해서 주로 발생한다. 보통 보수용 풀을 이용하거나 동일한 색의 벽지나 코킹을 덧대어 보수한다.



그림 3-4. 도배 뜰뜸, 좌(정상) / 우(하자)

##### ⑤ 도배지 터짐

도배지 터짐 현상은 초배지의 강도가 건조 수축되는 과정에서 인장력에 대응하지 못하는 경우, 도배를 위해 풀칠을 미리한 도배지의 끝 부분이 시공 전 바람에 말라 탈락하는 경우, 바탕면이 부실하여 탈락하는 경우, 외부적요소에 의한 접착력 부족 등으로 발생한다. 주로 콘센트, 현관 등 모서리나 각진 부분에서 발생한다. 기본적으로 온도, 습도 등 환경적인 요소에 의해서 주로 발생하며, 초배지와 바탕면 간의 접착력을 증진 시키는 방법으로 저감 시킬 수 있다.

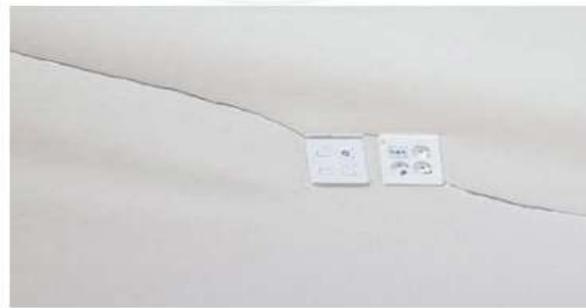


그림 3-5. 도배 터짐 현상

표 1. 도배하자 유형 및 원인/ 대책, 김진현(2011), 국토교통부(2020)

하자 유형	하자 원인	대책
이음부 접착불량	1. 소홀한 시공 2. 부적절한 자재 사용	1. 충분한 풀칠 2. 신중한 자재 선택
변색 및 곰팡이	1. 누수로 인한 습기 2. 시공자의 바탕 건조 불량 및 접착 제 과다 사용 3. 선시공 불량	1. 바탕을 충분히 건조시킨 후 재시공 2. 벽체 선시공 상태 확인 3. 내부결로 방지대책 강구
찢어짐 및 찢김	1. 자재 운반 시 등 타 공정 시공자 의 부주의	1. 현장기능공 주의 교육 2. 모서리부위 덧붙임 보양 3. 찢겨진 부위는 제거 후 재시공
도배들뜸	1. 기후로 인한 습기 영향 2. 초배지 오시공	1. 벽지 바르는 면 요철 제거 2. 결로, 습기 방지대책 강구
도배 터짐 갈라짐	1. 벽지 수축/팽창 시 발생하는 인장 력 2. 접착 불량	1. 벽지와 시공면의 부착력을 증진

## 2.2 기존 도배하자 관리 업무 현황 및 프로세스 조사

### 2.2.1 육안 조사의 한계

앞 2.1 절에서 조사한 내용과 같이 하자 품질 및 검측에 관한 부분에서 육안조사는 필수적으로 이루어지는 단계이다. 육안조사는 종류에 관계없이 시설물에 내재하여 있는 위험요인 및 하자를 사전에 발견하여 적절한 조치를 하는 부분에 있어 건설공사 품질확보에 결정적인 역할을 하고 있다.

그러나, 육안검사는 신체적인 부분에 절대적으로 의존하는 방법으로 수행되며, 이러한 부분에서 많은 제한사항이 발생한다. 신체적인 능력에 기초해 수행되는 만큼 관리자의 시각적인 선택에 영향을 많이 받는다. 한편, 변동 소요가 큰 건설 현장의 특성상, 관리자의 주의를 이끄는 요소가 예상치 못하게 다수 존재한다. 또한, 인간의 신체적인 한계상 선택적인 주의를 통해 다수의 상황 및 대상을 인식하는 경우는 존재하지 않는 상황에서 다양한 한계가 발생한다. 이러한 육안 검사의 오류는 측정자의 경험과 주어진 환경에 따라 변동 요소가

크나, 전반적인 산업 분야에서 육안 검사의 오류는 대략 30%로 판단하고 있다. 기존 육안 검사의 전반적인 산업 분야를 참고해 결과에 영향을 미칠 수 있는 부분에 대해서 조사 및 정리하였다. 본 연구에서는 Task, Environmental, Individual, Organization, Factor 총 4가지 요인을 기반으로, 육안검사에 미치는 요소를 분석하였다.

표 2. 건설 육안 품질점검 시 영향을 주인 요인 및 문제점, See(2017)

요인	세부요인 & 문제점
Task	체크리스트 상에 확인할 사항이 많음
	현장에서 판별하기 어려운 하자 내용이 많아 수행이 어려울 수 있음
	체크리스트 외에 다이내믹한 건설현장 상황에 따라 확인할 사항이 많음
Individual	품질점검자에 따라 점검방법, 순서, 중요사항이 상이할 수 있음
	품질점검자의 경험, 교육수준 정도에 따라 육안점검의 결과가 상이할 수 있음
	품질점검자의 피로도에 따라 육안점검 정밀성이 상이함
Organization	한정된 인원으로 점검 시, 점검자 당 많은 현장구역을 검사하므로 점검 정확도가 떨어짐
	책임소재가 불분명한 사항은 육안점검 결과에 영향을 미칠 수 있음
Environmental	날씨, 온도, 근무시간대, 점검 장소 특성(어두운 현장 등)에 따라 육안점검 정확도 영향 받음

### 2.2.2 공동주택 품질점검 프로세스

공동주택 현황 하자 관리업무는 크게 입주 전 하자와 입주 후 하자로 나누어 관리한다. 본 절에서는 입주 전 하자 관리 부분에 대해서 다룬다.

입주 전 하자는 크게 중간 품질점검, 입주자 사전 점검, 최종품질점검으로 나누어지며, 입주 전 하자 관리의 경우, 전문업체를 통한 사전 점검, 입주자 사전 점검 후 최종 품질점검으로 진행된다.

표 3. 입주전 하자 관리 프로세스, 오정환(2009)

		업무내용	입력정보	출력정보
입 주 전 하 자 관 리 (B/ S)	중간 품질점검	-점검 계획 -공용부 점검 -세대별 점검 -하자분류(업체별/평형별) -업체 사장단 회의 및 결과	-공용부 점검 Check list -세대별 점검 Check list -중간품질 점검계획	-중간품질 점검결과보고서 -업체별/평형별 점검결과 -업체별 조치계획 -업체별 처리방안
	입주자 사전점검	-입주자 사전점검 계획 -입주자 점검 진행 -입주자 점검결과 처리	-입주자 정보 -입주자 사전점검 계획 -세대별 / 부위별 Check list	-입주자 사전 점검표 -조치방안
	최종품질점검	-하자처리 이행 확인 및 점검 -최종 마무리 방법 및 일정 확정/조치	-업체별/평형별 점검결과 -입주자 사전 점검표 -중간품질 점검결과 보고서	-점검사항 조치여부 -최종마무리 일정

또한, 중간 품질점검 시 점검의 주체는 주로 시공사 현장 직원, 전문업체 등에 의해서 주로 실시 되며, 전유부분과 공동 부분을 전수조사하는 방식으로 진행된다. 그 후 식별된 하자를 처리하고, 입주자 점검을 실시 한다. 시설물 준공 점검은 사전 점검을 통해 식별된 하자를 취합하여, 시공사에게 전달하고 시공사는 해당 내용에 대한 하자를 확인 및 보수하는 과정을 통해 하자를 관리 하고 있으며, 입주 후 하자 처리 과정은 하자 발생시 세대별로 하자 처리를 진행하거나 현장에 본사 품질관리 직원이 상주해 직영 및 보수업체를 통해 하자를 처리하고 있다.

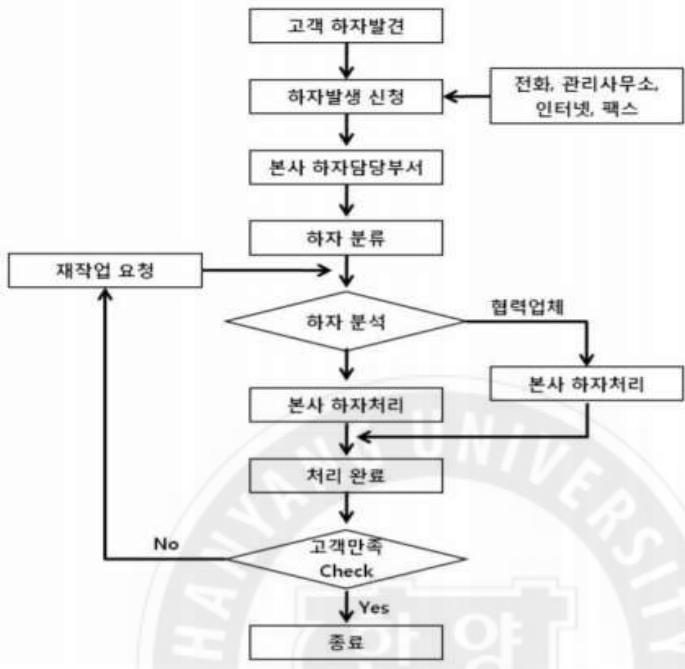


그림 4. 건설회사의 하자보수 처리 절차, 홍석일(2010)

입주자 사전 점검 시, 시공사의 하자보수 처리 절차는 다음과 같다. 일반적으로 고객인 입주자가 하자를 식별하여 이를 접수하면, 시공사의 품질관리 및 하자보수 부서에서 접수된 하자를 확인 및 분석하고 이에 따라 하자의 종류에 따라 직영으로 처리하거나 협력업체에 의해서 하자를 처리한다. 각 담당자는 하자보수 후 시공사의 하자보수 담당자에게 확인서를 제출 후 처리 과정의 고객만족도를 조사한다. 고객의 만족도가 높은 경우 하자 처리를 완료하고, 그렇지 않은 경우 다시 하자를 처리하는 과정을 거친다. 시공사 별로 하자 처리 과정에 차이점이 존재하나 보통 그림 5와 같이 진행된다.

### 2.2.3 아파트 하자 점검 업무 현황

기존의 건설사가 주관하는 중간품질점검은 보통 아파트 마감공사 완료 시 점인 입주 60일 이전에 전후하여 실시한다. 중간품질점검은 입주 후 하자를 처리하는 과정에서 입주자의 하자 처리 접수를 최소화하기 위한 단계이며, 이 과정에서 많은 수의 하자를 식별 후 조치하는 것이 중요하다. 공사 완료 시점에서는 다양한 마감 공정이 진행되며, 이러한 시점에서는 하자 관리 전담 인원이 부족하여 현장 내에서 전수조사 진행하는데 한계가 있기에 통상적으로 입주대행업체를 고용해 전수조사를 실시 한다. 입주대행업체는 보통 투입 3일 전 사전 교육 실시 후 품질점검 업무에 투입된다. 사전교육 시에는 보통 공용부 및 전유부분의 품질점검의 기준이 되는 체크리스트 항목에 대해서 교육을 실시하고 교육 내용은 건설 용어 및 관련 공정 내용 등이 추가 된다. 이러한 사전 교육을 진행한 후 공용부 및 세대별 점검을 진행하고 통상적으로 10일 내로 전체적인 점검이 완료된다. 점검 후 입주대행업체는 파악된 하자를 취합해 시공사에 인계하고 그 후 시공사는 취합된 하자 내역을 기초로 보통 입주자 사전 점검 이전까지 보수 및 재시공을 진행한다. 그림 4는 아파트 중간품질점검 프로세스이다.



그림 5. 기존 아파트 중간품질점검 프로세스

#### 2.2.4 아파트 하자 점검업무의 한계

기존의 입주대행업체가 주체로 진행 되는 하자 점검은 보통 육안 검사로 진행 된다. 앞서 말한 2.2.3절에서 검사에 투입되는 인원은 전문적인 부분이 미흡하며, 다음과 같은 한계가 있다.

첫째, 하자 관리 인원 개인에게 부여되는 점검량이 현장의 상황에 따라 차이가 크며, 이에 따른 업무의 부담이 크다. 통상적으로 점검량은 1,000세대 이상의 아파트 단지부터 3,000세대 이상의 대단지의 점검 업무를 수행할 수도 있다. 통상적으로 현장마다 모집인원은 다르지만, 모집공고 10건을 조사한 결과, 1,000세대 이상의 아파트를 점검하는 경우 평균적으로 30명 내외로 인원이 투입됨을 알 수 있다.

건설사는 기본적으로 세대 규모의 관계없이 중간 점검을 통해 식별된 하자를 입주자 사전 점검 이전까지 보수를 해야 하므로, 대략적 10일 이내 전수검사를 완료해야 한다. 또한, 하자 관리 인원은 단수하게 하나의 공종만을 점검하는 것이 아닌 표4에서도 확인할 수 있듯이 타일, 마루, 가구 등 하자 관리 인원 1인당 점검해야 할 부분이 다수 존재하며, 각 부위별 약 62가지의 하자가 발생할 수 있다. 때문에 2.2.1 절의 표3에서 정리한 것과 같이 하자 관리 인원이 점검해야 할 공종의 수가 많으며, 개인적 차이에 의한 업무에 대한 신체적인 능력이 상이하기에 사전 점검은 외부적인 한계 및 신체적인 한계로 인한 휴면 예리가 발생하기 쉽다.

표 4. 아파트 점검자의 공종별 점검 항목

점검부위&항목		제작사항								공종
바닥재(온돌마루/모노플)	플라보드	착질	소음	균형	부파	변색	이식	발霉	건축	
	이색판색	돌풀	오염	총길	오칠	파손	-	-	건축	
도배	길레보이풀풀	피복지털락	이동불풀	찢어짐	착김	돌풀	변색	오염	건축	
돌김 걸레판이 우물천장 원경 석고보드 벽체	도강풀풀	미색판색	파손	탈락	변형	착김	-	-	건축	
AI창호 창호틀(분합) 거실·별코니 창	비흡정 및 변형	황금장치풀풀	거제풀풀	흘리불당	래일불풀	파손	총길	-	건축	
	크립풀풀/날락	좌우바풀	유리파손	바람유입	콜로보이풀	-	-	-		
거실장	수명 수리불풀	미색면색	유리파손	거제불당	파손	총길	착질	-	건축	
거실장식벽(에드월)	이색판색	파손	총길	오염	-	-	-	-	건축	
천장 스위치 콘센트 등	부착불풀	작물불풀	파손	간접	총길	-	-	-	전기	
인터폰 HOME-AUTO	작물불풀	설지불풀	기능불당	화면불풀	갈음	흔선	-	-	전기	

둘째, 하자 관리 인원은 숙련도의 차이가 있다는 점이다. 점검 이전 단기간의 교육 진행 후 품질점검 업무를 실시하는데, 짧은 교육 기간 내에 높은 숙련도를 기대할 수 없다. 품질점검 체크 리스트 내용, 공정 및 건설 용어에 대한 교육을 진행하는데, 단기간에 습득하기는 어렵기 때문이다.

그래서, 대부분의 하자관리업체에서는 숙련도가 높은 인원을 선호한다. 그러나, 현실적으로 어렵기 때문에 비전공자 및 비숙련자들을 교육 후 투입하기 때문에 인원별 숙련도의 차이가 크다. 한편, '공동주택 하자의 조사, 보수비용 산정 및 하자 판정 기준' 개정안이 발표됨에 따라 하자들이 정확한 검측을 요구하고 있는 추세이며, 이러한 입주자의 수요에 따라 국토교통부는 공동주택 입주예정자 사전방문 및 품질점검단을 제도화하여 시공사로 하여금 높은 품질의 공동주택을 제공할 것을 요구하고 있다. 그러나, 기존의 품질점검 방식은 입주자와 정부가 요구하는 부분을 정확하게 반영하기 힘들다. 그리하여 보

다 정확한 기준을 토대로 하자를 검증하는 프로세스가 필요하다.

## 2.3 기존 하자 관리 연구 고찰

기존 하자 관리 연구의 동향을 살펴보면, 1) 하자 빈도 및 원인 2) 하자분류 체계 및 데이터베이스 구축 3) 하자관리 시스템 개발 4) 업무프로세스 개선 연구로 나누어진다. 본 연구의 목적은 기존에 진행된 하자 관리 업무를 보다 효율적이고 정확한 관리 시스템을 제안하는 것이므로, 앞선 하자 관리 프로세스의 현황을 분석하고 개선에 관한 동향을 고찰한다.

### 2.3.1 하자관리를 위한 시스템 개발

신형준 외(1996)은 공동주택의 효과적인 하자 관리 방안을 구축하기 위하여 다양한 연구를 토대로 시스템 구축을 위한 기초적인 방안을 제시하였다. 실제 사례를 분석하여 검증하였다. 하지만, 사례 분석을 통해 도출된 정보의 사용 방안을 효과적으로 제시하지 못하였다.

안광훈 외(2002)는 기존의 하자 사례 분석을 통해 하자 품질 관리 방안을 위한 시스템을 구축하였다. 이는 하자 정보를 기존 체크리스트와 같이 반영해 활용할 수 있는 시스템이다. 그러나, 하자 정보의 신뢰성을 검증할 방법이 명확하지 않아 초기 단계에서 전문가의 피드백을 통한 시스템 활용이 필수적이다.

또한 오세욱 외(2005)는 PDA와 같은 장치를 사용하고 웹 기반의 공동주택 하자 관리 시스템을 개발하였다. 또한 웹 활용을 기반으로 한 하자관리 시스

템을 통해 사용자 별로 업무 절차 확립을 통한 시스템을 개발하였다.

권오성(2013)은 건설 현장 3곳을 대상으로 기본적인 하자 사례 수집, 수집된 하자 사례에 대한 관리 시스템의 부재 등 기존에 행해졌던 하자 관리 업무의 문제를 확인하여 AR기법과 이미지 매칭 프로그램을 결합하여 DeMAR을 개발하여 건설 현장 하자관리 업무 프로세서를 제안하였다. 하지만, 이러한 하자관리 시스템은 마커 부착 위치를 작업자에게 매번 통보해야하며, 시스템 사용 시 동일한 마커는 인식이 되지 않는 등 시스템을 실무에 적용하는 부분에는 많은 문제가 발생하였다. 이러한 하자 관리를 위한 시스템 개발 동향은 표 5로 정리할 수 있다.

표 5. 하자 관리 시스템 개발 관련 연구

저자 (연도)	연구제목	주요 연구 내용
신형준 외 (1996)	건축물의 효율적인 하자관리 시스템 구축에 관한 기초연구	하자정보의 수집의 필요성을 제시하기 위한 기초적인 연구 수행
안광훈 외 (2002)	하자정보를 활용한 품질관리 시스템 개발에 관한 연구	하자정보가 반영된 체크리스트를 통해 하자 방지 시스템 개발 제안
오세욱 외 (2005)	PDA 및 웹 기반의 공동주택 품질점검 및 하자관리 시스템의 개발	PDA와 웹을 활용한 공동주택 하자 관리 시스템 개발
권오성 (2013)	이미지 매칭과 모바일 증강현실을 활용한 건설 현장 하자 관리 업무프로세스 개선 연구	이미지 매칭과 DeMAR를 활용한 건설 현장 하자관리 프로세스 제안 및 현장 적용 가능성 확인을 위한 실험 수행

하자 관리에 관한 기존 연구를 분석한 결과, 현장 내에서 발생하는 실질적인 하자 데이터를 직접 반영하는 부분에는 많은 제한사항이 있다. 또한, 대부

분의 연구에서는 공동주택 내에서 발생하는 모든 하자를 관리하는 시스템에 관한 연구를 진행하고 있지만, 전체적인 시스템 내 세부사항 별 하자 측정 방법에 대한 연구는 미흡한 실정이다.

따라서, 하자 관리 시스템을 구체화 하기 위해서 선행 되어야 하는 조건은 실제 하자 데이터를 조사하여 이를 통합적으로 관리하는 것을 기초로 하는 실질적인 하자 측정 방법에 대한 연구가 우선시 되어야 한다.

### 2.3.2 하자 관리 업무 프로세스 개선

석성준 외(2003)은 공동주택 입주자들의 하자보수 과정에 대한 만족도를 조사하였다. 그러나, 입주자들의 단순한 만족도 요소만 조사하여 해당 내용을 제시하였기에 명확한 대책을 제시하지 못했다.

서덕석 외(2007)은 공동주택 하자 소송의 유형과 문제점에 대해서 조사하였다. 그러나, 입주자의 입장에서 불만족의 원인에 대한 연구가 이루어지지 않았고 단순하게 소송을 통한 문제 해결 방안의 문제점만 언급하였기 때문에, 이를 해결하기 위한 대책이 요구 되고 있다.

하희윤 외(2007)은 하자 예방관리 프로세스에 관하여 하자보수 보증금을 최소화하는 방안을 고려하였으나, 하자 원인 저감 및 처리방안 제시는 이루어지지 않았다.

오정환(2009)은 품질 및 하자관리 통합 업무 프로세스를 통해 현행 하자관리 업무에 대한 한계를 해결을 위한 방안을 제시하였고, 이를 통해 입주자의

만족도 및 시공사의 이미지 상승에 기여할 수 있다고 주장했다. 그러나, 관련 프로세스를 실질적으로 사용 가능한지에 대한 검증하는 부분이 필요하다.

강현욱 외(2019)은 입주자 중심으로 이미지를 활용해 하자를 접수하고, 시공사 및 보수업체에게 실시간으로 이미지를 공유하고 해당 내용을 정확하게 전달하는 것을 중심으로 하는 시스템을 제안하였다. 그러나, 입주자의 입장에서 효율성을 판단하였기에 직접 계획 및 실시하는 시공사의 입장에서 검증이 필요하다.

이러한 하자 관리 업무 프로세스를 개선하기 위한 연구의 내용을 요약하면 표 6으로 정리될 수 있다.

표 6. 하자관리 업무 프로세스 개선 관련 연구 동향

저자 (연도)	연구제목	주요 연구 내용
석성준 외 (2004)	공동주택 하자처리 과정에 대한 거주자 입장의 만족도 분석	공동 주택의 하자 처리 업무 프로세스에 대한 사용자들의 만족도 분석
서덕석 외 (2007)	공동주택 하자소송의 발생형태 및 문제점에 관한 분석 연구	공동주택 하자 관련 소송에 대한 분석 및 소송에 대한 분쟁의 비효율성 제시
하희윤 외 (2007)	하자보수보증금 기반의 하자예방 관리에 관한 연구	하자 보증 보수금의 최소화를 위한 하자 관리업무 프로세스 제시
오정환 (2009)	공동주택 하자관리 업무프로세스 개선	하자관리 문제점을 파악하고 이를 해결하기 위한 품질/하자관리 업무 프로세스 제안
강현욱 외 (2019)	공동주택에 대한 하자정보 관리시스템의 개선 모델	거주자 중심에서 사진을 통해 하자 정보를 접수하고, 이를 건설회사 협력회사에 실시간으로 공유하는 시스템 제안

기존 프로세스를 분석한 결과, 건설 현장에서 발생하는 하자의 유형 조사 및 보수 방법을 주된 목표로 시스템과 프로세스의 활용 방안을 제시하고 있다.

또한, 기존 연구에 따르면, 업무 프로세스 개선을 목표로 하여 다양한 현장에서 하자 정보 수집 시스템을 기초로 의무적으로 하자 관련 유형 및 다양한 정보를 수집하고 있음을 확인할 수 있었다.

그러나, 수집한 정보에 대한 적절한 활용이 부족한 상황이며, 시스템 기준은 실제 하자의 현황을 반영하는 부분에 문제가 있다. 즉, 실질적인 하자 관리 검증 및 보수에 대한 부분이 미흡한 실정이다. 이러한 부분을 개선하기 위해 실질적인 하자관리에 필요한 검증 방법에 대한 연구를 통해 현실적으로 발생하는 하자에 대한 정확한 관리 시스템에 대한 선행 연구가 필요하다.

### 2.3.3 고찰 결과

기존 진행된 연구 결과, 대부분의 연구들의 전체적인 프로세스는 하자의 종류 분석 및 이를 저감 하는 방안, 하자 관리 및 예방 시스템을 통한 개선 방안을 제시하고 있다. 하지만, 근본적으로 발생하는 하자의 관리 방안에 대한 부분은 미흡한 실정이다. 또한 앞선 연구들은 하자 관리에 중점을 두고 실시하였지만, 발생 빈도가 높은 도배 하자를 정확하게 식별하는 방안에 대한 연구는 미미한 수준이다. 하자를 방지하는 프로세스를 구축하여도 현실적인 하자 발생의 빈도를 줄일 수는 없기에 본 연구의 필요성을 다시 확인할 수 있었다.

기본적으로 대부분의 연구는 하자의 전체적인 관리에 초점을 맞추고 이를 종합적으로 관리하는 방향으로 연구를 진행하였다. 또한, 본 연구에서 다루고자 하는 도배 하자의 경우에는 세부 하자 항목에 기초하여 하자의 발생 원인 및 저감 방안에 대해 중점적으로 연구를 진행하여 실질적인 업무관점에 대한 연구는 진행되지 않았다.

따라서, 본 연구에서는 기존 도배 하자의 저감 방안 및 기초적인 정보를 연구 하기보다는 실질적인 활용에 초점을 맞추어 기존 실시되었던 육안검사를 통한 방식보다 효율적인 방식을 제시하는 부분에서 차이가 있다.

## 2.4 컴퓨터 비전 분야의 이론 고찰

해당 연구는 컴퓨터 비전 기술을 이용하여 도배하자를 검출 및 관리하는 프로세스를 구성하는 것이다. 이번 장에서는 컴퓨터 비전 기술의 정의를 고찰하여, 이를 활용하기 위한 머신러닝 기법과 데이터 분류 방법과 이에 활용할 수 있는 기존 연구방식 중 머신러닝과 딥러닝 학습 모델을 기초로 하는 CNN에 대해서 연구하며, 특히, CNN을 기초로 하는 방식 중 Resnet에 대해 고찰할 예정이다.

### 2.4.1 컴퓨터 비전

컴퓨터 비전은 인공지능의 한 분야로서 시신경을 기초로 얻은 시각적인 요소를 활용하여 컴퓨터가 의사결정의 처리 과정을 모방하도록 하는 프로그램 연구를 말한다. 컴퓨터 비전은 물체를 유형별로 분류하거나, 자율주행 방식,

증강현실 등 다양한 부분에서 물체를 식별하거나 위치를 분석하는 방식으로 사용되고 있다. 여기서 스마트폰, 드론, 스캐너 등 다양한 형태의 카메라를 컴퓨터 인식에 활용한다. 이러한 방식으로 얻은 정보를 토대로 디지털 형식의 화상 자료를 생성해 컴퓨터로 해석하는 방식으로 진행된다.

컴퓨터 비전의 처리 과정은 크게 전처리(preprocessing)와 특징 추출(feature extraction)을 하는 저급 비전(Low-level vision)과 해석하는 고급 비전(High-level vision) 단계로 나눌 수 있다. 그림 6은 전체 과정을 간략하게 나타낸 것이다.

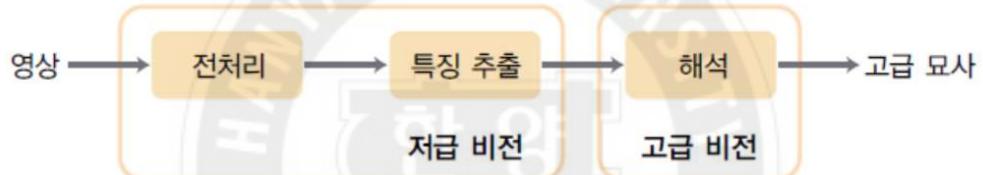


그림 6. 컴퓨터 비전의 처리 과정, 김명호(2019)

우선, 전처리 단계는 영상처리(image processing)을 이용하는 단계이다. 앞서 말한 렌즈를 통해 영상 정보를 얻고 이 정보를 화질개선, 크기 조절등의 활용 목적에 맞게 개선하는 과정을 진행한다.

특징 추출은 영상 정보를 토대로 저수준(Low-level) 즉 목표물의 기초적인 근간인 선의 기초로 특징을 추출하는 단계이다.

고급 비전(High-level Vision)은 앞선 단계에서 추출된 정보를 토대로 고급 묘사를 실시하는 단계를 말한다. 실행 방법은 객체 분류, 인식, 검출, 추적 등의 운용 목적에 따라 다르게 활용한다. 이에 따른 실행 방법은 SVM, 인공신경망 등을 기반으로 하는 머신러닝 기법들이 있다.

## 2.4.2 머신 러닝

머신 러닝은 인공지능(Artificial Intelligence ; AI)의 한 분야로 컴퓨터가 자체 학습을 통해 예측모형(Prediction Model)을 개발하는 것을 말하며, 패턴인식(기계학습)이라고 통칭할 수 있다. 일반적으로 학습은 많은 표본 데이터를 기반으로 이루어지며, 학습 데이터가 '입력(Input)'되면 이를 분석을 통해 통일성 및 규칙을 발견하는 과정이며, 추출된 정보를 기초로 하여 새로운 데이터에서 분류 및 예측 '결과(Output)'를 내는 것을 기본으로 한다. 최근에는 GPU, CUDA 기술과 같은 컴퓨터 하드웨어 및 클라우드 컴퓨팅(Cloud Computing) 기술 발전에 따라서 관심이 증가하고 있는 추세이다.

이미지 인식 프로세스는 시능력을 토대로 얻은 정보의 특징을 분석 및 활용하여 이미지의 종류를 인식할 수 있으나, 이를 토대로 얻은 결과는 비능률적이며, 정확하지 못한 연구 결과를 도출할 수 있다. 이러한 부분을 개선하기 위해 머신 러닝(Machine Learning) 알고리즘을 통하여 인식 프로세스 후 설계 과정에 대한 연구를 진행한다.

표 7. 학습 방식에 따른 머신러닝 알고리즘 분류, 심영종 외 4인(2020)

	<b>Supervised</b>	<b>Unsupervised</b>
<b>Continuous</b>	<ul style="list-style-type: none"><li>▪ Regression<ul style="list-style-type: none"><li>- Linear regression</li></ul></li><li>▪ Decision Trees</li><li>▪ Random forests</li></ul>	<ul style="list-style-type: none"><li>▪ Clustering &amp; Dimensionality reduction<ul style="list-style-type: none"><li>- PCA</li><li>- K-means</li></ul></li></ul>
<b>Categorical</b>	<ul style="list-style-type: none"><li>▪ Classification<ul style="list-style-type: none"><li>- Logistic regression</li><li>- SVM</li><li>- KNN</li><li>- Trees</li><li>- Naive-Bayes</li></ul></li></ul>	<ul style="list-style-type: none"><li>▪ Association analysis<ul style="list-style-type: none"><li>- Apriori</li><li>- FP-growth</li></ul></li><li>▪ Hidden Markov model</li></ul>

머신러닝은 3가지 부분인 지도학습(Supervised Learning), 비지도학습(Unsupervised Learning), 강화학습(Reinforcement Learning)으로 나눌 수 있다.

머신러닝은 주로 지도학습(Supervised Learning)을 활용한다. 기존에 식별된 데이터의 범주(Category)를 스스로 판단하는 데이터 분류 문제(Classification)를 개발하고 다방면의 데이터를 처리하는 부분에 활용한다. 머신러닝에서 대표적인 알고리즘은 의사결정트리(Decision Tree), 베이지안망(Bayesian Network), 서포트 벡터 머신(Support Vector Machine), 인공신경망(Artificial Neural Network), 강화학습, KNN 등이 있다. (하희륜, 2017)

### 2.4.3 Classification

Classification은 지도학습(Supervised Learning)의 일종으로 기존에 존재하는 데이터의 범주의 관계성을 분석하고, 새로운 데이터의 범주를 스스로 분석하는 과정이다. 예를 들어 단순한 하나의 항목을 분석하여 분류하는 것과 같은 이항분류(Binary Classification), 셋 이상의 범주를 분류하는 다항분류(Multi-class Classification)가 있다. 다항분류는 비지도학습의 Clustering과 비슷하지만, 큰 차이점은 범주의 도메인의 정의 유무이다. 지도학습의 분류는 이미 정해진 범주 내에서 새로운 데이터를 학습 후 분류한다. 그러나, 비지도학습의 Clustering은 우선 정해지지 않은 범주를 생성하여, 분류하는 방식으로 진행되는 것이 가장 큰 차이점이다. (하의륜, 2017)

이러한 Classification을 적용하기 위한 기존의 머신러닝의 방법은 다음과 같이 정리할 수 있다.

## (1) K-Nearest Neighbor

K-Nearest Neighbor은 데이터를 분류하고 새로운 데이터 포인트의 범주를 선정하는 경우 K개의 인접한 포인트를 선정하고 그 중 가장 많은 선택을 받은 포인트의 범주로 이 데이터를 새롭게 분류하는 방식이다. (Sun, 2015)

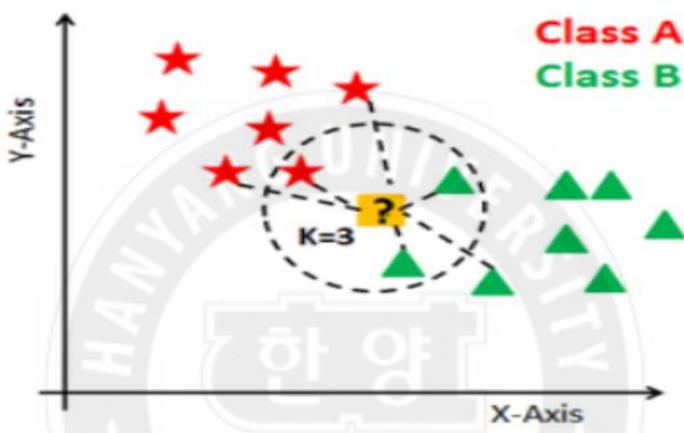


그림 7. KNN 알고리즘, Sun(2015)

KNN에서 우선적으로 확인해야 하는 사항은 다음과 같다. 우선 알고리즘의 핵심 부분은 대상이 되는 부분과의 거리를 측정하고 이를 계산하는 방법이다. 계산 시 무조건적으로 유clidean의 거리 측정 방법을 사용하는 것은 제한되어야 한다. 모든 데이터 열을 동일한 방식으로 처리하면 예상치 못한 변수로 인해 오류가 발생할 가능성이 있다. 이를 해결하기 위해 거리의 제곱을 합산하기 이전 각 범주별 평균거리 측정 후 이를 제외하는 방식 등 다양한 거리 계산 알고리즘을 활용하는 것이 중요하다. 예를 들어 실수 데이터의 경우 유clidean 거리 측정 방식을 사용하고, 범주형 혹은 이진 데이터 등 데이터 해밍 거리 측정 방식을 활용하는 것이다. (Sun, 2015)

표 8. KNN 알고리즘의 거리 측정의 방식, Sun(2015)

City block distance	Euclidean distance	Mahalanobis distance	Cosine distance
$d_1(\mathbf{x}, \mathbf{y})$ $= \sum_{l=1}^N  \mathbf{x}_l - \mathbf{y}_l $	$d_2(\mathbf{x}, \mathbf{y})$ $= \sqrt{\sum_{l=1}^N  \mathbf{x}_l - \mathbf{y}_l ^2}$	$d_3(\mathbf{x}, \mathbf{y})$ $= \sqrt{(\vec{\mathbf{x}} - \vec{\mathbf{y}})^T \Sigma^{-1} (\vec{\mathbf{x}} - \vec{\mathbf{y}})}$	$d_4(\mathbf{x}, \mathbf{y})$ $= \mathbf{1} - \frac{\vec{\mathbf{x}} \cdot \vec{\mathbf{y}}}{ \mathbf{x}  \cdot  \mathbf{y} }$

## (2) 서포트 벡터 머신(Support Vector Machine)

서포트 벡터 머신 즉 SVM은 머신러닝 학습 알고리즘 중 대표적인 것 이다. SVM 알고리즘은 신경망 내 식별 이론과 선형 분류를 기초로 근사적 매개변수(Parament)를 찾아내는 알고리즘을 말한다. 선형 분류는 측정한 데이터를 선형적으로 분리하여 초 평면(Separable)으로 만드는 방법이고 초 평면의 매개변수 값을 기초로 하여 gradient method의 방식으로 수정하여 활용하는 방법을 신경망이라 한다. 선형적 분류를 기초로 하여 발전하는 SVM은 분류 문제나 회귀의 문제에도 활용된다.

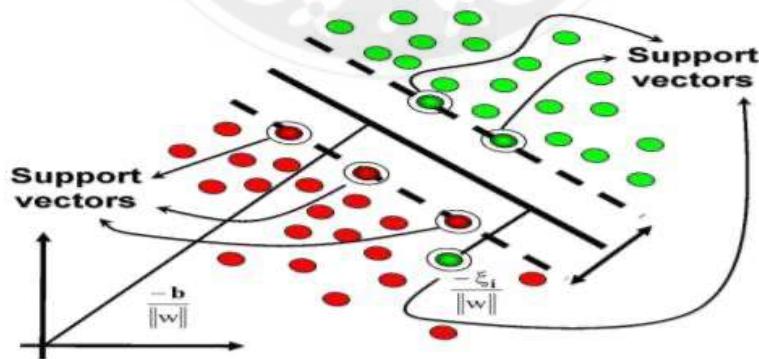


그림 8. SVM의 처리 과정, 하의륜(2017)

## 제 3 장 컴퓨터 비전 기술을 활용한 하자 관리 제안

### 3.1 딥 러닝

딥 러닝은 머신러닝의 한 부분으로 연속된 정보에서 특정 기준을 기초로 하여 이미지의 객체를 추출하는 방식을 말한다. 방대한 이미지 데이터 중 특정 기준의 데이터 세트를 활용하여 판정 기준값을 설정하는 것이라고 정의할 수 있다. 딥 러닝은 보통 몇 개의 단계로 구성 되어진 간단한 구조부터 수십 개의 단계로 이루어진 복잡한 네트워크로 이루어져 있다. 이러한 다양한 정보를 임계치를 기준으로 한 필터를 활용해 기준에 맞게 정확하게 다단계의 정보 추출하는 것이라고 말할 수 있다. 즉, 영상 데이터의 복합적인 구조를 다수의 단계를 기초로 한 학습 방식의 기술을 의미한다. 변형 모델 중 CNN을 활용한 영상데이터 활용 방법은 딥러닝의 구조를 인간의 시각적인 데이터로 표현하기 위한 부분에서 가장 뛰어난 성능을 나타내고 있다.

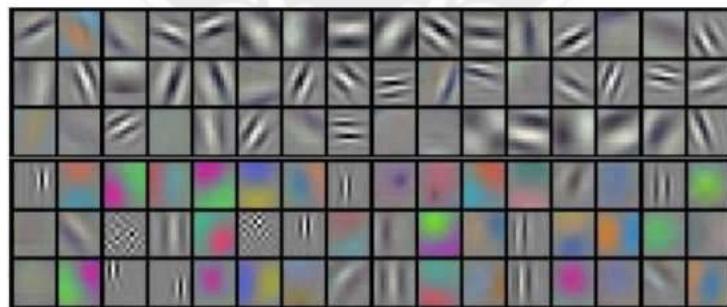


그림 9. 딥러닝 학습모델을 이용한 처리 및 학습 과정, 하의륜(2017)

딥러닝은 비형식 데이터인 컴퓨터 비전, 통역 및 이미지 데이터 인식 등 다

양한 부분의 데이터 처리 부분에서 다른 머신러닝 알고리즘 보다 뛰어난 능력과 가용성을 나타내고 있다. 딥러닝에서 활용 부분에 따라 CNN(Convolutional Neural Network), RNN(Recurrent Neural Network), RBM(Restricted Boltzmann Machine), DBN(Deep Belief Network) 등의 많은 학습 모델로 나누어진다. (하의륜, 2017)

### 3.1.1 CNN

딥러닝의 한 분야인 CNN은 이미지 인식을 기초로 딥 러닝 학습 모델 중 하나이다. CNN은 인간의 시신경이 정보를 인식 후 이를 처리 및 활용하는 과정이며 이미지 인식에 최적화된 컴퓨터 비전(Computer Vision) 분야 중 하나의 모델이다. 이러한 알고리즘은 1989년 얀 리쿤 교수가 문자 인식을 위한 딥러닝 기술로 처음 제안되었다. (Lecun et al, 1999)

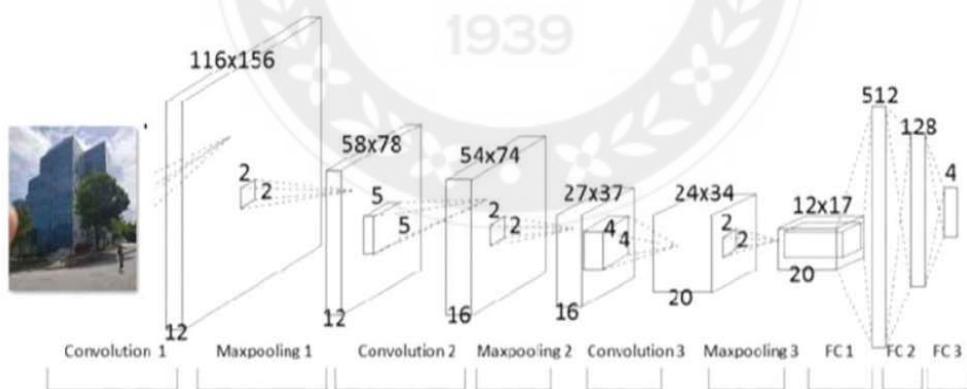


그림 10. CNN Network 구조, 이효찬 외 3인, 2020

그림 9에서 나타나 있듯이 콘볼루션 계층(Convolution Layer), 풀링 계층(Pooling Layer), 분류 계층(Classification Layer)로 나누어진다. 콘볼루션 계

층에선 이미지의 특징을 우선 판단하여 이를 기초로 특징을 추출하기 위한 콘볼루션을 수행한다. 시각적인 단계에서 외부적인 변형 요소 등에 영향을 최소화하며 일관적인 결과를 추출하기 위해 이러한 과정을 반복한다. 이러한 단계를 진행하며 지역적인 특징으로부터 전역적인 특징을 얻게 된다. CNN에서 분석 능력을 극대화를 위해 보다 세부적인 정보를 인식하여 추론의 정확성을 높이는 방법을 활용하고는 하는데 그 중 하나는 레이어의 수를 늘려 활용하는 방식이다. 하지만 이러한 방법은 충분한 데이터의 표본이 존재하는 경우에만 활용할 수 있다. 네트워크의 구성이 완벽하여도 데이터의 표본이 다수 존재하지 않는 경우 좋은 학습의 결과를 만들어 낼 수 없다. (이효찬 외 3인, 2020)

CNN은 영상데이터를 직접 활용하는 방식으로 사용되며 특징벡터의 입력층을 활용하지 않는 방식이라는 것에 주목할 필요가 있다. CNN의 운영방식은 우선 수집된 영상 데이터는 컨볼루션 층에서 특징이 추출되고 이어서 완전 연결층을 통해 분류되어 활용된다. 즉, CNN은 자체적으로 인식된 데이터의 분류와 특징 추출을 진행하며 이 경우 물체의 형상을 직접 모델링 하지 않아도 이를 성공적으로 수행할 수 있다. 그렇기에 딥러닝이 본격적으로 활용 되는 상황에서 과거 우선시 되었던 데이터 수집 및 모델링 과정을 최소화 하여 시간을 단축하고 이를 데이터 인식의 최적화를 위한 알고리즘을 구성하는 방법을 연구하는 경향으로 바뀌었다. (이효찬 외 3인, 2020)

2012년 이후 다양한 CNN의 모델이 나타났지만, 최적의 결과를 도출하는 학습 모델을 구성하기 위해 연구를 진행하는 추세이다. 우선 최적의 CNN 학습 모델을 리스트업 하여 세부 구조를 분석하고 재구성하여 다양한 학습 모델에 활용한다. 표9는 2012년 이후 활용되는 CNN 학습 모델이다. (하의륜, 2017)

표 9. CNN 학습 모델의 구조, 하의륜(2017)

학습 모델	AlexNet	VGG	GoogLeNet	ResNet
계층	8	19	22	152
Top-5 오차	16.4%	7.3%	6.7%	3.57%
합성 층	5	16	21	151
합성곱	11, 5, 3	3	7, 1, 3, 5	7, 1, 3, 5
연결 층	3	3	1	1
연결 사이즈	4096x1000	4096x1000	1000	1000
구조 타입	딥 타입	딥 타입	폭 타입	순환 타입

### 3.1.2 Resnet

#### (1) 정의

Resnet은 신경망이 깊어질수록 발생하는 문제를 해결하기 위한 아이디어로 잔차학습(Residual Learning)을 적용한 모델이다. 이를 활용해 Resnet은 이전까지 존재하던 다른 CNN 모델(AlexNet 5개층, VGGNet 19개층, GoogleNet 22개층)과는 다르게 100층 이상에서도 높은 정확도의 성능을 이끌어내서 2015년 ImageNet Large Scale Visual Recognition Competition (ILSVRC)에서 오류율 3.6%로 1등을 차지하였다.

#### (2) 원리

Resnet에서 사용한 잔차 학습의 원리는 기존 신경망의 학습 목적이 입력(X)을 학습을 통해 목적함수  $H(x)$ 를 찾는 것이라면 잔차 학습은 출력에서 입력을 빼주는 잔차( $F(x) = H(x)-x$ )에서 입력(x)을 더해 주는  $F(x)+x$ 를 목적 함수  $H(x)$ 로 사용하는 것에 있다. 아래 그림에서 오른쪽이 Residual

Block을 나타낸다. 기존의 신경망과 차이가 있다면 입력값을 출력값에 더해 줄 수 있도록 지름길(ShortCut)을 하나 만들어준 것이다.

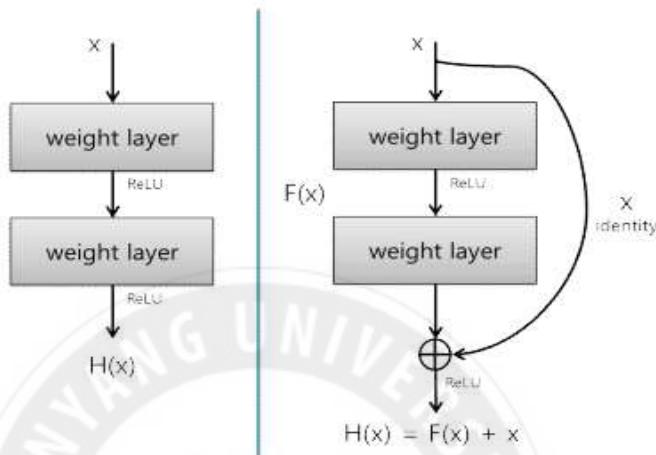


그림 11. 기존 CNN 학습모델(좌)과 Resnet(우)의 학습 원리, He et al.(2016)

기존의 신경망은 입력값  $x$ 를 타겟값  $y$ 로 매핑하는 함수  $H(x)$ 를 얻는 것이 목적이었다. 그러나 Resnet은  $F(x)+x$ 를 최소화하는 것을 목적으로 한다.  $x$ 는 현시점에서 변할 수 없는 값이므로  $F(x)$ 를 0에 가깝게 만드는 것이 목적이 된다.  $F(x)$ 가 0이 되면 출력과 입력이 모두  $x$ 로 같아지게 된다.  $F(x) = H(x)-x$ 이므로  $F(x)$ 를 최소로 해준다는 것은  $H(x)-x$ 를 최소로 해주는 것과 동일한 의미를 지닌다. 여기서  $H(x)-x$ 를 잔차(Residual)라고 한다. 즉, 잔차를 최소로 해주는 것이므로 ResNet이란 이름이 붙게 된다.

### (3) 구조

기본적으로 VGG-19의 형태를 기초로 ResNet을 구성한다. 그 후 추가로 컨볼루션 층들을 활용해 폭 넓게 더하여 지름길(ShortCut)을 구성한다. 한

마디로 ResNet은 Identity Block과 Convolution Block로 구성되며 아래 그림과 같이 구성된다.

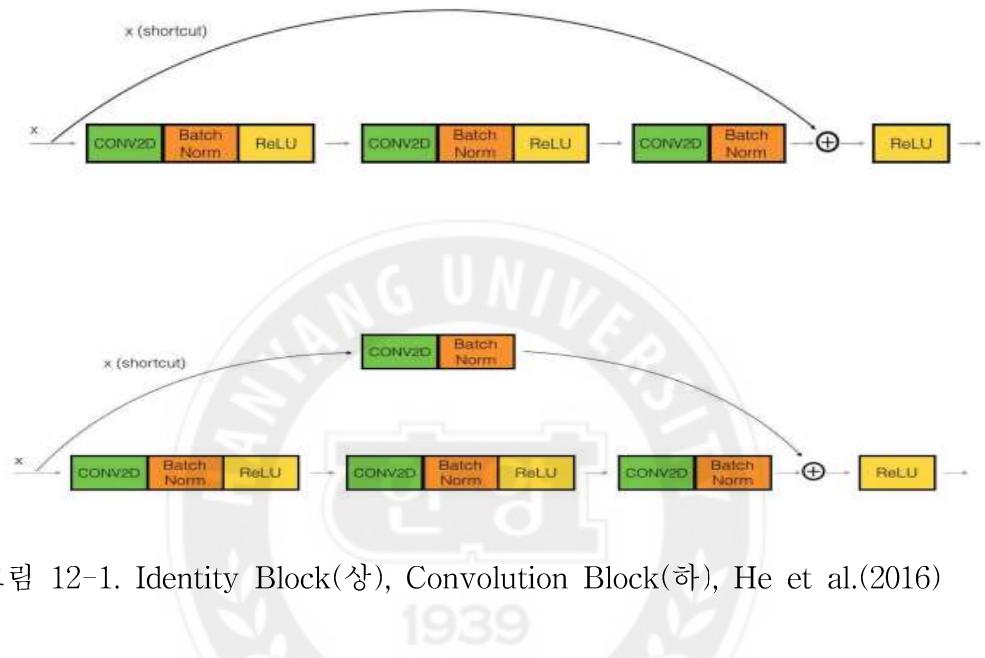


그림 12-1. Identity Block(상), Convolution Block(하), He et al.(2016)

여기서 Identity Block은 네트워크의 Output  $F(x)$ 에  $x$ 를 그대로 더하는 것을 뜻하며, Convolution Block은  $1 \times 1$  Convolution 연산을 거친 후  $F(x)$ 에 더하는 것이다. 그래서 이러한 두 가지 Block을 아래와 같이 쌓아서 구성한 것이 ResNet의 구조이다.

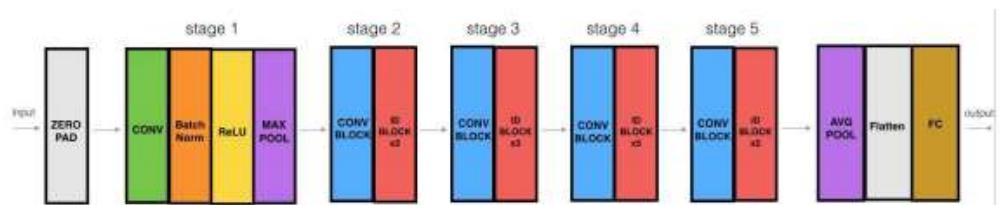


그림 12-2. Identity Block(상), Convolution Block(하), He et al.(2016)

### 3.2 CNN을 활용한 물체 인식법

이미지의 분류와 그것을 기초로 물체의 현 위치 인식, 물체를 세분화 등 세 가지의 유형으로 이미지 인식 프로세스를 분류할 수 있다.

이미지의 분류는 첫 번째로, 해당 이미지의 전체에 하나의 세부적인 기준을 부여한다. 두 번째로, 물체 형상 세분화는 이미지의 세부적인 특정 기준에 부합하는 모든 이미지 자료를 픽셀 단위로 재구성하여 나타낸다. 마지막으로, 물체의 위치 인식 및 탐지는 이미지 내에서 특정 기준에 충족하는 모든 이미지 자료의 개별 위치를 파악하는 것을 말한다. 물체의 위치를 주로 경계 상자(Bounding Box)의 형태로 표시한다. 이러한 차이는 다음과 같이 표현할 수 있다.



그림 13. 딥러닝 모델을 이용한 물체 인식법 분류 : (a) 물체 분류, (b) 물체 탐지, (c) 물체 세분화, 김병현 외(2019)

CNN 모델은 분류된 범위의 입력 이미지 데이터를 바탕으로 분류될 기준의 수와 동일한 수의 Fully-Connected Layer와 이를 연결하는 Pooling Layer 및 활성화 함수의 조합을 기초로 이미지 분류를 수행한다. 이미지 분류를 위한 데이터는 간단하게 생성할 수 있다. 우선, Layer 구축 방법은 이미지 하나의 클래스만 우선 부여하여 사용 가능하다는 장점이 있다. 대표적인 모델에는 AlexNet (Krizhevsky et al, 2012), VGG-16 (Simonyan & Zisserman, 2014) 및 ResNet(He et al., 2015)이 포함된다.

물체 탐지 모델은 분류된 이미지 데이터에서 기준에 맞는 데이터에 적합한 모든 데이터의 개별 위치를 탐지하는 역할을 수행 한다.

물체 탐지 모델은 다수의 슬라이딩 윈도우의 크기를 다양하게 변화시켜 대상이 될 확률이 가장 높은 부분을 추출한다. 세부적인 역할 수행 방식은 우선, 분류된 데이터를 기초로 윈도우의 크기를 다수의 모델링 한 후 기준에 가장 적합한 부분을 추출하는 방식으로 이루어진다. 물체 탐지 모델은 물체의 위치를 박스의 형태로 표기하는 방식이므로 보다 물체의 위치를 선정하는데 용이 하다.

물체의 형상 세분화 모델은 분류된 데이터에서 세분화 기준의 모델을 선정 후 픽셀 단위로 영역을 선정 후 진행한다. 따라서 일반적인 CNN과는 달리, 결과를 픽셀 단위로 출력할 수 있도록 모델 전체를 Layer로 구성하는 방식을 채택한다. 또한 대부분의 물체 형상 세분화 모델은 픽셀 단위로 클래스를 제공하기 위해 입력 계층과 출력 계층의 크기를 동일하게 부여할 수 있도록 설계되며 물체를 픽셀 단위로 세분화하므로 물체의 형상을 정확하게 추출할 수 있는 장점을 갖는다. (심영종 외 4인, 2020)

### 3.3 컴퓨터 비전 기술을 이용한 건설 분야 연구 동향

이번 장에서는 기존 건설 부분에서 활용되던 컴퓨터 비전 기술에 대해서 연구 및 분석한다. 현 추세에 맞게 컴퓨터 비전 기술 뿐만 아니라 딥러닝을 활용한 다양한 부분을 도입하기 위한 연구가 이루어지고 있으며 이를 활용해 기존 건설 시설물 하자 점검의 문제를 해결하고 보다 효율성과 정확성을 증진 시키기 위해 연구가 진행 중이다. 이러한 연구를 기초로 하여, 본 연구의 방향을 설정한다.

기존 컴퓨터 비전 기술을 이용한 건설 분야의 연구 동향을 살펴보면 크게 1) 디지털 이미지 획득 및 분석 2) 구조물 손상탐지 3) 시공 관리 기술 연구로 나누어진다. (심영종 외 4인, 2020)

본 연구의 목적은 기존보다 효율적인 하자탐지 / 관리 시스템을 제안하는 것 이므로, 이와 유사한 주제인 구조물 손상탐지에 관련된 연구 동향을 고찰한다.

#### 3.3.1 구조물 손상 탐지

최근에는 시설물 하자 검출에 다양한 딥 러닝(Deep Learning) 기술 중 영상 인식 및 분류에 특화된 딥러닝 알고리즘 합성곱 신경망(Convolutional Neural Network, 이하 CNN)을 적용한 연구들이 진행되고 있다. (정서영, 유정호, 2019)

이는 주로, 콘크리트 구조물의 균열이나 토목 시설에서의 균열을 탐지하는 것을 주제로 했다.

Cha et al. (2017)은 콘크리트 표면과 균열 이미지를 분류하는

CNN(Convolutional Neural Network)을 구현하고 이를 이용하여 균열이 발생한 콘크리트 표면 이미지를 슬라이딩 윈도우 방식으로 스캔하여 탐지하는 방식을 제안했다.

Zhang et al. (2017)은 딥러닝 모델의 연산 효율성 향상을 목적으로 자주 사용되는 풀링 레이어(Pooling Layer)를 사용하지 않는 방식을 채택하여 이미지 균열 탐지의 정확성이 향상된 CNN을 개발했다.

Tong et al. (2018)은 아스팔트 균열 탐지를 위한 2단계 접근법을 제안하였다. 손상을 포함할 가능성이 높은 이미지들을 K-Means Clustering 분석을 사용하여 미리 선택하고, 선택한 이미지에서 CNN을 이용한 균열 탐지를 수행하였다.

Yang et al. (2017)은 모델 전체를 Convolution Layer로 구성한 Fully Convolution Network를 사용하여 하자 및 손상을 탐지하고 픽셀 수준에서 손상의 정도를 측정하였다.

이호범 외(2012)는 디지털 영상을 활용한 처리 기술을 이용해 균열 검출 시스템을 개발해 콘크리트의 구조물을 검출하는 연구를 진행하였다. 또한 스티칭 기술 도입을 통해 다수의 이미지를 하나의 통일된 이미지로 구성하는 방식을 통해 도출된 결과의 효율적인 관리 또한 가능하도록 연구를 진행하였다. 이러한 시스템을 통해 40m 너비의 교량 슬라브에서 0.2mm의 폭을 가진 균열을 탐지하였다.

그러나 지금까지 종합된 균열 및 하자 평가 기술 대부분은 실질적인 활용을 통해 적용되지 않고 현장 실험 및 실험실 내에서만 실시되었다. 따라서 실제 활용 시엔 영상 기반 기술의 원활한 사용을 위해 계속된 연구를 통해 개선 시킬 필요가 있다. (심영종 외 4인, 2020)

또한, 지금까지의 디지털 영상 활용 기술은 건축물의 손상 탐지 부분 중 구

조 하자 부분에서 주로 사용 되었으나, 효율적인 사용을 위한 방식으로는 현 추세에 맞게 공동주택의 주된 하자 분쟁 발생 원인 중 가장 높은 비율로 나타나는 마감공사를 중점적으로 한 연구는 진행되지 않고 있다.

따라서, 다량으로 발생해 완벽한 육안 탐지 등이 어렵고, 입주자들의 불만 사항에 직결 되는 도배하자에 대한 손상탐지 기술을 제안하는 부분에서 다른 연구와의 차이점을 가지고 연구를 진행할 예정이다.

### 3.3.2 물체 인식 딥러닝 알고리즘 실험의 비교 및 분석

선정된 데이터 이미지나 특징을 인식하기 위한 딥러닝 모델은 2.4.8 절에서 제시된 바와 같이 1) 영상 분류모델(Classification Model), 2) 물체 탐지 모델(Detection Model), 3) 물체 세분화 모델(Segmentation Model)로 나누어 활용하였다. 김병현 외 4인(2020)은 딥러닝을 이용한 콘크리트 구조물 손상탐지 과제에서 균열탐지에 적합한 모델을 선정하기 위해 앞서 말한 3가지 기준을 바탕으로 모델링 하여 학습시키고 각자의 기능을 비교하였다.

우선 각각의 모델 분류 기준은 서로 다른 이미지 인식 형식을 통해 진행되기 때문에 이에 맞는 알고리즘을 우선 체계화를 위해, 그림 13과 같이 빨간색으로 데이터 표본에 균열 영역을 각각 1) 영상 분류모델, 2) 물체 탐지 모델, 3) 물체 세분화 모델 학습에 적합한 유형으로 변형시켰다.

추가로 성능 비교를 위한 모델링 학습을 위해 균열 이미지 400장, 검증을 위한 균열 이미지 100장을 확보하였다.

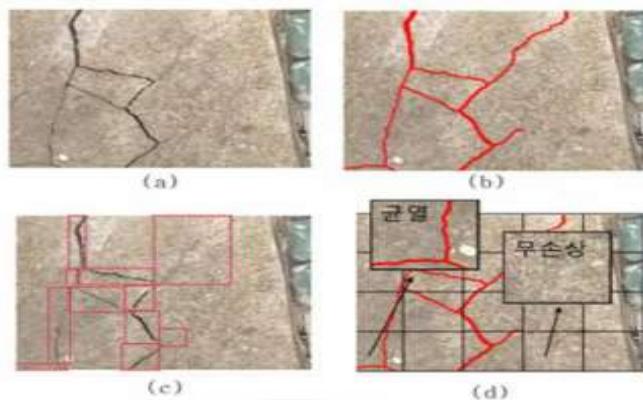


그림 14. 모델별 균열탐지 성능 비교용 데이터 : (a) 원본 이미지, (b) 물체 세분화, (c) 물체 탐지, (d) 영상 분류 모델, 김병현 외(2019)

각 균열 이미지 학습을 진행하였고, 모델별로 이미지 학습은 학습용 이미지와 검증용 이미지로 구분하여 모델별 이미지 학습을 실시 했다. 정확한 결과 도출을 위한 학습 데이터 확보를 위하여 이미지 증강 기술의 상하반전 및 좌우 반전을 사용하였다.

평가 기준 항목으로 이미지 데이터 내에서 기능을 평가하는 학습 정확도 (Training Accuracy)와 학습에 활용되지 않은 데이터를 활용하여 기능을 평가하는 검증 유효성(Validation Accuracy)의 두 가지 기준을 통해 검증을 실시했다.

표 10. 모델별 균열 이미지 학습과 탐지 결과, 김병현 외(2019)

구분	영상 분류	물체 탐지	물체 세분화
학습 이미지 (장)	2000 (학습 1400, 검증 600)	500 (학습 400, 검증 100)	500 (학습 400, 검증 100)
이미지 증강 기술	상하반전 좌우반전	상하반전 좌우반전	상하반전 좌우반전
학습 결과	Train accuracy (%)	100	96.2
	Validation accuracy (%)	98.79	94.6
			96.2

이미지 학습 결과로 영상 분류 모델(Classification Model)을 적용하였을 경우 학습의 정확도와 검증의 유효성 부분이 가장 높은 결과가 도출됐다.

### 3.4 이론 및 기존 연구 고찰 결과

현재 건설 분야에서는 컴퓨터 비전 기술을 기초로 한 연구를 통해 기존의 수행되었던 시설물 하자 측정에 대한 문제점을 해결하고 정확도 및 효율성 증진을 위한 연구를 진행하는 추세이다.

그 중 본 연구와 유사한 구조물의 손상탐지 분야의 경우 주로 손상 탐지의 대상은 구조 하자를 중점적으로 진행되었으나, 현 추세에 맞는 공동주택 하자 중 가장 높은 비율을 차지하는 마감공사에 대한 하자 손상 여부 탐지에 관한 연구는 진행되지 않는 실정이다.

건설 현장에서 발생하는 하자 사례의 경우 주로 경험을 기초로 하여 측정 및 관리 되기 때문에 정형화된 데이터 측정이 어려워 신뢰도가 떨어지는 데 이터가 많다. 그리하여, 정확도와 신뢰도를 기초로 한 데이터 수집을 최우선 시 해야 하며, 이를 기초로 체계적이며 정형화된 방식으로 데이터 수집 후 토

대로 모델링 하여야 한다. 이를 위해 단계별로 데이터를 객관화해야 하고, 이미지 데이터의 형태별 분류 기준을 확립하여야 한다. (심영준 외 4인, 2020)

2.1.3절에서 언급한 바와 같이, 도배하자의 경우 복합적인 하자로 분류할 수 있다. 주로 도배하자의 경우 현장의 환경적인 요소, 작업자의 숙련도 및 작업 상황 등 물리적인 요소 등으로 이루어진 복합적인 하자이다. 과거 이러한 하자 데이터를 체계적으로 분류한 시도가 많지 않았고 하자 관리 분류 체계에 관한 연구는 미흡한 추세이다. 따라서, 다량으로 발생해 사람의 신체적인 부분에 기초해 탐지가 힘들고, 하자 분쟁 발생 비율이 높은 마감공사 중 도배하자에 관한 손상탐지 기술을 제안하는 부분에서 다른 연구와의 차별점을 갖는다.

따라서 본 연구는 김진현(2011)의 연구와 국토교통부(2020)에서 명시한 도배 하자의 5가지 유형을 기준으로 머신 러닝(Machine Learning)의 이미지 학습 모델 중 분류 모델(Classification Model)을 적용하여, 공동주택 도배하자를 식별하는 모델링 프로그램을 구축하고자 한다.

## 제 4 장 학습 데이터

이번 장에서는 도배 하자를 스스로 식별하고 구분하는 모델링 프로세스를 구축하기 위해 CNN 학습 모델 중 Resnet50을 기반으로 한 이미지 식별 알고리즘을 활용하려고 한다. 앞선 장에서 학습의 데이터를 정의했고 본 연구의 학습 데이터 이미지는 신축 공동주택 현장 내에서 수집한 이미지 중 도배하자 의 5가지 분류 기준에 해당하는 이미지 데이터로 구축하였고, 데이터 및 학습의 정확도를 높이기 위해 Data Augmentation을 실시하였다.

추가로 Resnet50을 기초로 수집된 데이터에 대한 학습을 통해 수집한 Image Data를 각각 훈련과 평가 데이터 셋으로 나누어 학습을 실시 했고, 이를 기반으로 모델링의 정확도와 성능을 자체 평가하였다.

최종적으로 시스템 구축 후 생성된 시스템의 정확도를 확인하기 위해 정의한 도배 하자 기준의 총 10,000장의 이미지로 구성된 시험용 데이터 셋을 구축해 해당 시스템에 적용 및 신뢰성을 판단한다.



그림 15. 연구 방법

## 4.1 학습 데이터 정의

본 연구에서 이미지 데이터에서 식별되는 하자가 어떤 범주에 속하는 경우를 자동 식별을 목표로 한다. 추가로 손상탐지 중 하자 자체의 유무를 확인하는 것이 기초가 되어야 하므로 정상 데이터를 추가해 총 6가지의 분류 기준을 데이터를 학습시킨다.

즉, 학습용 데이터는 1) 도배지 찍힘, 2) 이음부 접착불량, 3) 곰팡이 및 오염 4) 도배지 들뜸 및 터짐, 5) 정상 총 5가지의 경우로 분류한다. 분류 기준 중 4) 도배지 들뜸의 경우 도배 초배지 시공 간 불량으로 짜배기 모양으로 들뜬 경우로 한정하여 연구를 진행하였다.



그림 16. 학습 데이터의 4가지 범주

## 4.2 데이터 수집

공동주택의 하자 식별 간 하자 데이터의 경우는 대부분 시공사 내에서 직접 기록 및 관리된다. 보통 이러한 식별 데이터의 경우 내부 정보로 공유되어지므로, 외부에서 직접 확인하기엔 어려운 부분이 있다. 그리하여 직접 공동주택 신축 현장에서 실제 도배하자 데이터를 확보하였다.

앞서 말한 3.1절에서 정의한 하자 유형 4가지(도배지 찍힘, 이음부 접착불

량, 곰팡이 및 오염, 도배지 터짐, 도배지 들뜸)의 경우의 하자 이미지를 수집하였고, 이를 기초로 이미지 학습을 위한 데이터 셋을 항목별로 약 500장씩 총 2,000장을 확보하였다.

구성한 CNN 학습의 정확성을 향상 시키기 위해 데이터를 상하/ 좌우 반전시키거나 진폭을 달리해 이미지를 변형시켰다. 이를 통해 1장의 이미지를 대략 3~4장으로 변형 및 확장 시켜 데이터 셋을 구성했다.

따라서 각 하자 별 이미지 데이터의 경우 각 하자 분류 기준 별 5,000장으로 확장 시켰고, 총 20,000장의 데이터를 확보하였다.

데이터 확장에 사용된 알고리즘은 머신 러닝용 Python 기반 라이브러리 ‘Augmentor’를 활용하였다. 그림 17-1은 Augmentor를 적용해 데이터를 증강하는 코드를 활성화한 것으로, 그림 17-2은 확장된 데이터의 예이며, 해당 사례의 경우 벽지 들뜸의 데이터 중 1개를 Augmentor를 통해 확장한 결과이다.

```
img = Augmentor.Pipeline("D:\jeon\augment\data\hold")  
img.flip_left_right(probability=1.0)  
img.flip_top_bottom(probability=1.0)  
img.random_distortion(probability=1, grid_width=10, grid_height=10, magnitude=8)  
img.sample(5000)  
  
img = Augmentor.Pipeline("D:\jeon\augment\data\wall")  
img.flip_left_right(probability=1.0)  
img.flip_top_bottom(probability=1.0)  
img.random_distortion(probability=1, grid_width=10, grid_height=10, magnitude=8)  
img.sample(5000)  
  
img = Augmentor.Pipeline("D:\jeon\augment\data\split")  
img.flip_left_right(probability=1.0)  
img.flip_top_bottom(probability=1.0)  
img.random_distortion(probability=1, grid_width=10, grid_height=10, magnitude=8)  
img.sample(10000)  
  
img = Augmentor.Pipeline("D:\jeon\augment\data\tare")  
img.flip_left_right(probability=1.0)  
img.flip_top_bottom(probability=1.0)  
img.random_distortion(probability=1, grid_width=10, grid_height=10, magnitude=8)  
img.sample(5000)
```

그림 17-1. Augmentor 적용을 통한 데이터 증강

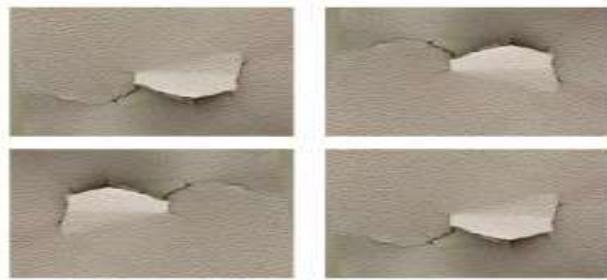


그림 17-2. Data Augmentor 결과

표 11. 전체 학습 데이터 목록

학습 데이터	분류	Training Data
벽지하자	Mold	5,000
	Spall	5,000
	Tare	5,000
	Split	5,000

### 4.3 Resnet50 알고리즘을 이용한 모델 학습

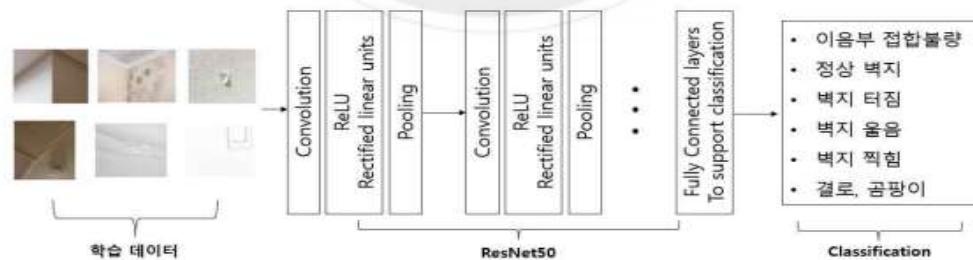


그림 18. Resnet50을 이용한 CNN Training

벽지 하자 종류 검출을 위해 CNN 학습을 진행한다. Resnet50을 기초로 CNN 학습을 진행한다. 학습을 위해 Tensorflow에서 전이학습(Transfer Learning)을 진행하였다. 전이학습이란 다른 목적을 위해 이미 학습된 모델의 가중치(Weight)들을 전송(Transfer)하여 자신의 모델에 맞게 학습을 시키는 방법을 말한다. 신경망의 이러한 재학습 과정을 세부 조정(Fine-Tuning)이라고도 한다. 전이학습은 보유한 Image Data Set이 작거나 시간을 절약하기 위해 사용한다.

본 연구에서 이미지 데이터의 학습에 관하여 특정 기준을 충족하는 CNN 모델로 Resnet50을 사용해 연구를 진행하며 이를 통해 학습된 모델의 정확도를 분석하고자 한다. Python언어와 Tensorflow 딥러닝 라이브러리를 활용해 모델 학습을 진행하였고, 하드웨어와 소프트웨어의 컴퓨터 환경은 다음과 같다.

OS	Windows 10 Pro 64 bit
CPU	Inter® Core™ i7-6700HQ CPU
RAM	8GB
GPU	NVDIA GeForce GTX 960M
Software	Anaconda 3.21.4 Cuda 11.4 Python 3.8.8

표 12. 모델 학습을 위한 컴퓨터 환경

추가로 CNN 기반의 Resnet50을 활용해 기계학습을 진행하였고, 해당 Resnet50의 모델은 다음과 같다.

표 13. 기계학습을 위한 Resnet50 모델

Model: "sequential"		
Layer (type)	Output Shape	Param #
resnet50 (Functional)	(None, 2048)	23587712
flatten (Flatten)	(None, 2048)	0
dense (Dense)	(None, 516)	1057284
dense_1 (Dense)	(None, 1024)	529408
dense_2 (Dense)	(None, 512)	524800
dropout (Dropout)	(None, 512)	0
dense_3 (Dense)	(None, 256)	131328
dropout_1 (Dropout)	(None, 256)	0
dense_4 (Dense)	(None, 128)	32896
dropout_2 (Dropout)	(None, 128)	0
dense_5 (Dense)	(None, 4)	516

Total params: 25,863,944  
Trainable params: 2,276,232  
Non-trainable params: 23,587,712

본 연구는 이미지 데이터를 기반으로 학습 결과의 신뢰성을 위해 Keras의 Image Data Generator 클래스를 활용했다. Image Data Generator는 이미지를 사용할 때마다 임의로 변형을 가함으로 기존 인식된 데이터보다 많은 데이터를 학습을 시키는 효과를 주어 과적합(Over Fitting)되는 것을 막고, 이미지 데이터를 보다 효과적으로 분석 및 분류할 수 있게 된다.

또한 20,000장의 데이터 모두 180 x 180 크기로 변환해 데이터 학습을 진행하였다. 이미지 데이터 학습을 진행하는 경우 이미지 데이터를 모두 같은 크기로 전처리 과정을 선행 진행 후 학습하는 것이 좋다.



그림 19. Train/Validation 데이터 분할 과정

또한 전체 20,000장의 데이터의 과적합(OverFitting)을 최소화하기 위해 데이터를 Train/Validation을 활용해 분할 과정을 거쳤다.

이러한 과정은 Train/Test를 활용하는 기존 프로세스를 Data Set을 Train/Validation으로 일정 비율로 쪼갠 후 후속 학습 진행 시 Train Set으로 학습을 진행하고, 학습 진행 간 Validation Set으로 학습된 모델을 활용하는 것이다. 본 연구에서는 전체 데이터 셋 중 20%를 Validation Set으로 지정하였다.

앞선 데이터의 결과는 표14와 같이 나타났으며, 그림19의 경우 데이터 전처리 과정을 나타낸 코드 중 일부이다.

```
In [ ]: import matplotlib.pyplot as plt
import numpy as np
import os
import glob
import PIL
import tensorflow as tf
from tensorflow import keras
from tensorflow.keras import layers
from tensorflow.python.keras.layers import Dense, Flatten
from tensorflow.keras.models import Sequential
from tensorflow.keras.optimizers import Adam

In [ ]: DATADIR = "D:\Jeon\data\Test"
CATEGORIES = ["Fault1", "Fault2", "Fault3", ...]

for category in CATEGORIES:
    path = os.path.join(DATADIR, category)

In [ ]: img_height, img_width = 180,180
batch_size = 32
train_ds = tf.keras.preprocessing.image_dataset_from_directory(
DATADIR,
validation_split = 0.2,
subset = "training",
seed = 123,
label_mode = 'categorical',
image_size = (img_height, img_width),
batch_size = batch_size)

In [ ]: val_ds = tf.keras.preprocessing.image_dataset_from_directory(
DATADIR,
validation_split = 0.2,
subset = "validation",
seed = 123,
label_mode = 'categorical',
image_size = (img_height, img_width),
batch_size = batch_size)
```

그림 20. 학습 데이터 전처리 코드

표 14. Training Data, Validation Data

학습데이터	분류	Training Data	Validation Data
벽지하자	Mold	4,000	1,000
	Spall	4,000	1,000
	Tare	4,000	1,000
	Split	4,000	1,000

이후 연구 진행 방식은 우선 데이터 학습에 필요한 변수 및 학습 방식을 설정한다. 우선, 학습에 대한 알고리즘 구성의 경우 손실함수와 훈련과정, 모니터링 방식을 선정해야 한다.

첫 번째로, 손실함수 중 하나인 Categorical-Crossentropy 함수를 활용해 연구를 진행하며, 손실함수를 최소화하는 방향으로 가중치(w)와 역치(k)를 수정했다.

두 번째로, Adam을 활용해 훈련과정 중 최적화하는 방향으로 학습을 유도했다.

마지막으로, Accuracy와 Loss를 지정해 훈련과정을 모니터링 하였으며, 이를 지정해 학습 과정의 정확도를 높인다.

이어서 훈련 횟수(Epoch) 및 그 외 학습에 필요한 변수들을 설정하였고, 이를 활용해 표 15로 정리하였다.

```

resnet_model = Sequential()

pretrained_model = tf.keras.applications.ResNet50(include_top = False,
                                                 input_shape = (180, 180, 3),
                                                 pooling = 'avg', classes = 4,
                                                 weights = 'imagenet')
for layer in pretrained_model.layers:
    layer.trainable = False

resnet_model.add(pretrained_model)
resnet_model.add(Flatten())
resnet_model.add(Dense(516, activation = 'relu'))
resnet_model.add(Dense(1024, activation = ('relu'), input_dim=512))
resnet_model.add(Dense(512, activation = ('relu')))
resnet_model.add(Dropout(.4))
resnet_model.add(Dense(256, activation = ('relu')))
resnet_model.add(Dropout(.3))
resnet_model.add(Dense(128, activation = ('relu')))
resnet_model.add(Dropout(.2))
resnet_model.add(Dense(4, activation = ('softmax')))
```

그림 21. 학습 방식 설정 코드

표 15. 모델학습을 위한 변수 설정값

Parameter	Value
Optimizer	Adam
Learning Rate	0.001
Validation split	0.2
Loss	Categorical Crossentropy
Epoch	150
Image height & Width	(180, 180)

## 제 5 장 모델 성능 검증 및 평가

### 5.1 평가 방법

해당 학습 모델에 대한 평가는 크게 2가지로 나누어진다.

첫 번째, 구축한 시스템 모델의 성능을 우선 분석 및 평가한다. CNN 모델의 정확성을 증명하는 방식은 여러 가지가 있으나, Classification에 주로 사용되는 증명 방식은 모델 성능 지표가 있으며, 이는 크게 Confusion Matrix, F-Score, Accuracy, Precision, Recall이 있다.

#### (1) 오차 행렬(Confusion Matrix)

오차 행렬(Confusion Matrix)은 각 인스턴스의 실제 클래스와 예측 클래스의 개수를 행렬의 성분에 채워 넣은 것이다. 아래 오차 행렬에서는 각 열에 예측 클래스를 각 행에 실제 클래스를 배치하고 있다. 본 연구에서는 표 14에서 제시된 데이터를 학습용 데이터 셋(Learning Data Set)과 모델 평가용 데이터 셋(Validation Data Set)으로 각각 8:2 비율로 분할 하였고 임의의 모델 평가용 데이터 셋을 구현된 학습 모델에 투입하여 나온 결과를 토대로 오차 행렬을 구성한다.

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) <i>Type II Error</i>	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) <i>Type I Error</i>	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
	Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$	

그림 22. Confusion Matrix의 구성

해당 행렬을 이루는 값은 True/False Positive와 True/False Negative로 이루어진다.

True Positive는 실제 라벨 True 값은 모델 예측이 정확한 경우를 의미한다. 반대로 False Positive는 False 라벨 값을 True로 잘못 예측한 경우를 말한다.

True Negative는 실제 라벨 False인 정답을 False라고 예측한 경우를 의미하며, False Negative는 실제 True를 False로 예측한 경우를 의미한다.

## (2) F-Score

F-Score(F-measure)는 정밀도와 재현율 수치를 빠르게 확인하기 위해 사용한다. 이 중 가장 대중적으로 사용되는 것은 F1-Score이다. 이 것은 정밀도와 재현율의 조화평균으로 정리하면 아래와 같게 나타낼 수 있다.

$$(F1-score) = 2 \times \frac{1}{\frac{1}{Precision} + \frac{1}{Recall}} = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

### (3) Accuracy

정확도는 전체 데이터 중 판별된 True 값의 데이터 비율로 다음과 같게 나타낼 수 있다.

$$(Accuracy) = \frac{TP + TN}{TP + FN + FP + TN}$$

### (4) Precision & Recall

정밀도는 Positive로 예측한 인스턴스 중에 True 값의 비율을 말한다. 재현율은 실제 클래스가 Positive인 인스턴스를 식별한 정도를 나타내며 민감도 (Sensitivity)라 나타낸다. 이러한 것은 다음과 같게 나타낼 수 있다.

$$\text{Precision} = \frac{\sum TP}{\sum TP + FP}$$

$$\text{Recall} = \frac{\sum TP}{\sum TP + FN}$$

[Precision(정밀도), Recall(재현율)]

두 번째로, 해당 학습 모델을 불러와 테스트용 이미지 Data Set을 구분하는 방식으로 진행했다. 해당 Data Set의 이미지 내에 각 항목에 해당되는 하자 1개만을 포함한다.



그림 23. Test Data Set

## 5.2 모델 성능 지표

Resnet의 성능 지표는 정확성 및 상실율 두 가지 요소로 확인한다.

그림24, 그림 25는 반복학습의 결과로 모델링 프로그램의 정확도 및 상실율의 양상을 보여준다.

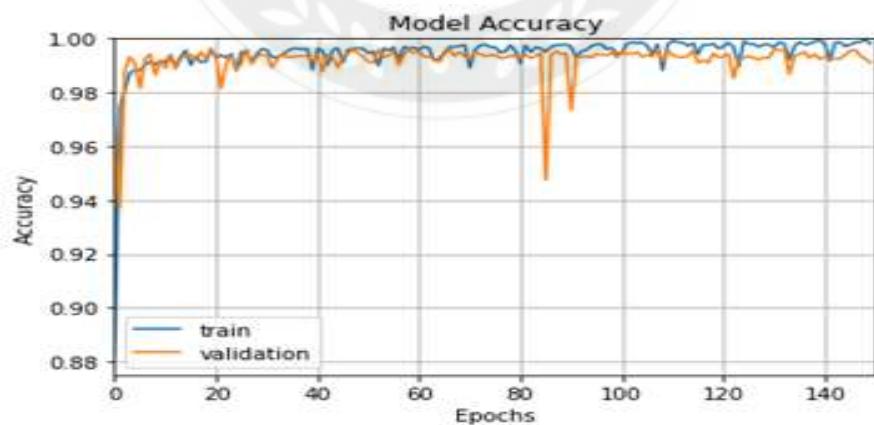


그림 24. 누적 학습에 따른 모델의 학습 정확도

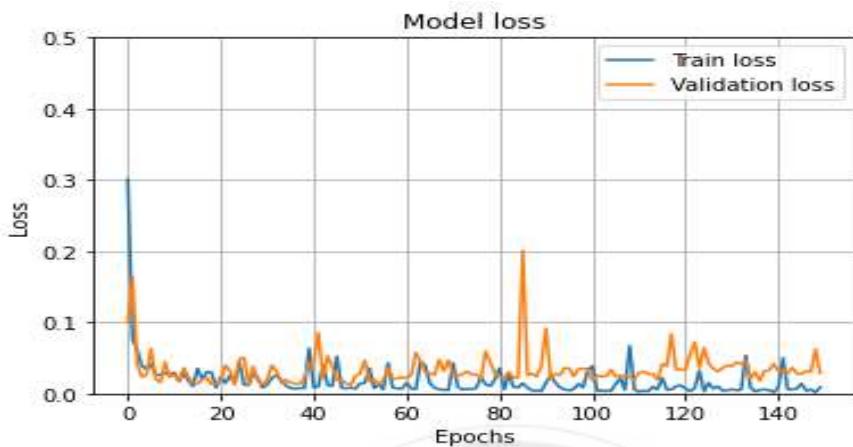


그림 25. 누적 학습에 따른 모델의 학습 손실율

표 16은 작성된 오차 행렬을 계산하여 작성된 모델 성능 지표이다. 해당 지표는 Precision, Recall, F1-Score, Support가 활용되었다.

표 16. Precision, Recall, F1-Score, Support

	precision	recall	f1-score	support
mold	0.26	0.26	0.26	208
spall	0.21	0.21	0.21	193
split	0.28	0.28	0.28	223
tare	0.25	0.25	0.25	208
accuracy			0.25	832
macro avg	0.25	0.25	0.25	832
weighted avg	0.25	0.25	0.25	832

### 5.2.1 검증 결과

모델 평가용 데이터 및 실질적인 검증 진행 결과의 정확도를 측정한 결과 Classification Result는 4가지 분류 각각 평균 0.25로 나타났으며, 표16에서 나타낸 것과 같이 4가지 분류를 기준으로 한 학습의 정확도는 100%에 가까운 평균 정확도를 보였다.

표 17. 검증 결과 요약

	데이터 수	정답 수	오답 수
Mold	2,000	1,999	1
Spall	2,000	2,000	0
Tare	2,000	2,000	0
Split	2,000	1,998	2
Total	8,000	7,997	3
평균 정확도		99.96%	

표17의 경우로 예측 결과를 정리하였다. 특히 도배지 터짐(Split)의 경우 이 이미지의 불규칙함 및 해상도의 문제로 도배짐 찢김(Tare), 도배지 들뜸(Spall)의 경우와 혼동되었다고 판단된다.

### 5.3 이미지 예측

실제 공동주택 신축 현장에서 도배하자 이미지를 수집하였고 이를 4가지의 분류 기준으로 선정해 학습된 모델에 임의의 테스트 이미지를 투입해 분류하도록 하였다.

본 실험에서 해당 이미지들을 행렬 배열로 전환 후 이 데이터를 학습된 데이터 모델에 투입해 해당 이미지에 배당된 범주(Category)를 예측하도록 하

였다.

마지막으로, 예측된 결과의 값을 이미지와 함께 나타냈다. 이를 수행하기 위한 코드는 학습 전후로 구분해 그림 26과 같이 진행하였으며, 이를 통해 출력되는 예측 결과의 예시이다.

```
image=cv2.imread("G:\jeon\dataset\hold\hold_original_1x.PNG_5aa9c840-e0ef-49d5-9c1c-74f4d36562d8.png")  
image_resized= cv2.resize(image, (img_height,img_width))  
image=np.expand_dims(image_resized, axis=0)
```

```
pred=resnet_model.predict(image)
```

```
output_class=class_names[np.argmax(pred)]  
print("The predicted class is", output_class)
```

The predicted class is tare

```
image2=cv2.imread('G:\jeon\dataset\spall\spall_original_1.PNG_f75873fd-c47d-4674-a9f1-7c85f2277bd2.png')  
image2_resized= cv2.resize(image2, (img_height,img_width))  
image2=np.expand_dims(image2_resized, axis=0)
```

```
pred2=resnet_model.predict(image2)
```

```
output_class=class_names[np.argmax(pred2)]  
print("The predicted class is", output_class)
```

The predicted class is tare

```
image3=cv2.imread("G:\jeon\dataset\split\split_original_nnn.PNG_B72713b8-0044-4650-ad2d-7ae2dcbb255a.png")  
image3_resized= cv2.resize(image3, (img_height,img_width))  
image3=np.expand_dims(image3_resized, axis=0)
```

```
pred3=resnet_model.predict(image3)
```

```
output_class=class_names[np.argmax(pred3)]  
print("The predicted class is", output_class)
```

The predicted class is tare

```
image4=cv2.imread("G:\jeon\dataset\tare\tare_original_1.PNG_b18cfa8f-943c-4148-b3bf-d56d20dd42d3.png")  
image4_resized= cv2.resize(image4, (img_height,img_width))  
image4=np.expand_dims(image4_resized, axis=0)
```

```
pred4=resnet_model.predict(image4)
```

```
output_class=class_names[np.argmax(pred4)]  
print("The predicted class is", output_class)
```

The predicted class is tare

그림 26-1. 학습 전 이미지 예측 코드

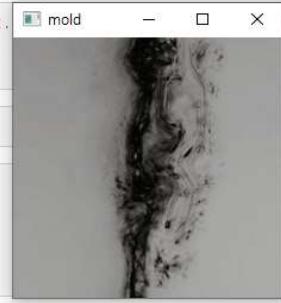
```

image_=cv2.imread("G:\jeon\dataset\mold\mold_original_1x.jpg")
image_resized= cv2.resize(image_, (img_height, img_width))
image=np.expand_dims(image_resized,axis=0)

pred=resnet_model.predict(image)

output_class=class_names[np.argmax(pred)]
show = cv2.imshow(output_class, image_)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

```



The predicted class is mold

```

image3_=cv2.imread("G:\jeon\dataset\split\split.jpg")
image3_resized= cv2.resize(image3_, (img_height, img_width))
image3=np.expand_dims(image3_resized,axis=0)

pred3=resnet_model.predict(image3)

output_class=class_names[np.argmax(pred3)]
show = cv2.imshow(output_class, image3)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

```



The predicted class is split

```

image_=cv2.imread("G:\jeon\dataset\mold\mold_original_1x.jpg")
image_resized= cv2.resize(image_, (img_height, img_width))
image=np.expand_dims(image_resized,axis=0)

pred=resnet_model.predict(image)

output_class=class_names[np.argmax(pred)]
show = cv2.imshow(output_class, image_)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

```



The predicted class is mold

```

image2_=cv2.imread('G:\jeon\dataset\spall\spall_original.jpg')
image2_resized= cv2.resize(image2_, (img_height, img_width))
image2=np.expand_dims(image2_resized,axis=0)

pred2=resnet_model.predict(image2)

output_class=class_names[np.argmax(pred2)]
show = cv2.imshow(output_class, image2)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

```



The predicted class is spall

```

image2=cv2.imread('G:\jeon\data\spall\spall_original.jpg')
image2_resized= cv2.resize(image2_, (img_height,img_width))
image2=np.expand_dims(image2_resized,axis=0)

pred2=resnet_model.predict(image2)

output_class=class_names[np.argmax(pred2)]
show = cv2.imshow(output_class, image2_)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

The predicted class is spall

```

```

image3=cv2.imread("G:\jeon\data\split\split.jpg")
image3_resized= cv2.resize(image3_, (img_height,img_width))
image3=np.expand_dims(image3_resized,axis=0)

pred3=resnet_model.predict(image3)

output_class=class_names[np.argmax(pred3)]
show = cv2.imshow(output_class, image3_)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

The predicted class is split

```

```

output_class=class_names[np.argmax(pred4)]
show = cv2.imshow(output_class, image4_)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

The predicted class is tare

```

그림 26-2. 학습 후 이미지 예측 코드

### 5.3.1 검증 결과

앞선 테스트의 이미지 모델을 투입해 예측 정확도를 측정한 결과, 99%이상의 평균 정확도를 보였다. 이는 앞선 4.2절에서 제시된 모델 정확도(99%)와 비슷한 수치이다. 가장 높은 정답율을 보인 항목은 도배지 들뜸(Spall), 도배

지 찢김(Tare)은 (100%)이며, 다음으로는 곰팡이 및 오염(Mold), 도배지 터짐(Split)의 순서로 높은 정답율을 보였다.

앞선 4.2절에서 가장 높은 정답율을 보인 도배지 들뜸은 본 테스트에서 동일하게 높은 정확성을 보여주었고, 도배지 터짐(Split)의 경우 인식율이 상승한 모습을 보여줬다. 다음과 같이 진행한 시험 2가지에서 가가 기록된 항목별 예측 순위와 평균 정확도는 표 19와 같다.

```

image_=cv2.imread("G:\jeon\dataset\mold\mold_original_1x.jpg")
image_resized= cv2.resize(image_, (img_height,img_width))
image=np.expand_dims(image_resized,axis=0)

pred=resnet_model.predict(image)

output_class=class_names[np.argmax(pred)]
show = cv2.imshow(output_class, image)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

The predicted class is mold

```

```

image2_=cv2.imread('G:\jeon\dataset\spall\spall_original.jpg')
image2_resized= cv2.resize(image2_, (img_height,img_width))
image2=np.expand_dims(image2_resized,axis=0)

pred2=resnet_model.predict(image2)

output_class=class_names[np.argmax(pred2)]
show = cv2.imshow(output_class, image2)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

The predicted class is spall

```

```

image3_=cv2.imread("G:\jeon\dataset\split\split.jpg")
image3_resized= cv2.resize(image3_, (img_height,img_width))
image3=np.expand_dims(image3_resized,axis=0)

pred3=resnet_model.predict(image3)

output_class=class_names[np.argmax(pred3)]
show = cv2.imshow(output_class, image3)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

The predicted class is split

```

```

output_class=class_names[np.argmax(pred4)]
show = cv2.imshow(output_class, image4_)
print("The predicted class is", output_class)
cv2.waitKey(0)
cv2.destroyAllWindows()

```

The predicted class is **tare**

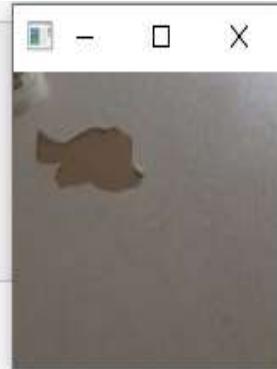


그림 27. 항목별 모델링 학습 후 이미지 인식 결과

표 18. Data Set 예측 결과

	데이터 수	정답 수	오답 수
Mold	2,000	1,999	1
Spall	2,000	2,000	0
Tare	2,000	2,000	0
Split	2,000	1,998	1
Total	8,000	7,998	2
평균 정확도	99.97%		

표 19. 시험1,2의 항목별 예측 순위 및 평균 정확도

	시험1	시험2
Mold	3	3
Spall	1	1
Tare	1	1
Split	4	3
평균 정확도	99.96%	99.97%

## 제 6 장 결론

본 연구에서는 도배 하자를 자동으로 식별하는 시스템 구축을 위해 CNN을 기반으로 하는 이미지 분류 알고리즘을 활용했다.

특히, CNN 기반의 학습 모델 중 Resnet50을 기반으로 연구를 진행했다.

연구 학습 결과, 누적 학습 수가 일정 수준 이상일 때 모델의 정확도 (0.26/0.21/0.28/0.25)로 1에 수렴하는 결과를 보여줬다. 이후 약 20,000회의 추가적인 데이터 학습을 통해 벽지 하자 분류 학습 모델링을 완성했다.

또한, 학습 후 초기에 빠르게 정확도 1에 수렴한 이유는 Resnet 모델의 고유 특성으로 학습 중 발생한 오류를 추가 연산을 진행해 차 회 학습에 반영하는 잔차 학습(Residual Training)에 의한 것으로 분석된다.

종합적인 연구의 결과로는 본 연구 진행 간 실험 1의 경우 곰팡이 및 오염 (Mold), 도배지 터짐(Split)의 경우에 3개의 오검출이 발견되었으며,

실험 2의 경우 곰팡이 및 오염(Mold), 도배지 터짐(Split)의 경우 2개의 오검출이 발견되었다.

또한, 학습 모델 구현에 사용된 이미지 데이터를 기반으로 진행한 모델 자체 정확도 측정 결과 99.96%의 높은 정확도를 보였고, 직접 수집한 하자 이미지 판별 간 99.97%의 정확도를 보였다. 종합하여, 실제 현장 내에서 임의의 데이터를 수집 후 해당 연구 모델링을 활용해 하자 식별 간 높은 하자 검출율을 보여줄 것으로 기대 된다.

이러한 성공적인 결과를 도출해 낼 수 있던 결과로는 우선 각 항목별 1,000 개 이상의 데이터 셋을 활용해 이미지 분류 학습 모델을 생성한 부분이 핵심적인 요소로 판단된다.

본 연구는 주택 마감 공사 중 가장 하자 발생율이 높고 정확한 육안 식별이 어려운 도배하자를 자동 식별하는 모델을 구축했다는 부분에서 큰 의의가 있다. 또한 아파트 중간, 마무리 품질 점검에 투입되는 인력에게 요구되는 높은 업무 강도와 점검자 개인의 능력에 의존해 발생한 휴면에러(Human Error)를 줄이고 효율성을 극대화를 위한 자동 하자 식별 모델을 제시했다는 점에서 의의가 있다.

그러나, 해당 연구를 진행하여 제시된 모델은 현장 내 발생하는 다양한 도배 하자 중 1개의 하자만을 식별하는 Multi-Class Classification을 기반으로 한 모델이기에 2개 이상의 하자를 식별하는 부분에서 제한이 있다. 이미지 식별 간 이미지 내 2개 이상의 하자가 있는 경우에도 2개 이상을 식별할 수 없는 것이다. 즉 이러한 부분에서 현장 내 해당 모델을 활용해 점검 시에 여러 종류의 벽지 하자가 동시에 발생하더라도 해당 모델로 대응할 수 없다는 부분에서 제한성이 존재하는 문제가 있다.

해당 문제는 기존 방식과 별개로 Multi-Label Classification을 기반으로 학습 모델을 구축한다면 2가지 이상의 하자가 발생하는 경우 모든 하자를 동시에 식별하여 해당 문제를 해결할 수 있다.

향후 연구 과제는 제안 시스템의 두 방면에 집중해 발전 및 연구한다.

첫째, 성능 향상이다. 이번 경우 많은 이미지 데이터를 활용해 실험환경 및 실제 연구 결과 높은 정확도를 보였다. 그렇지만 다양한 상황에서 임의의 데이터 식별 시 높은 정확도를 위해 데이터 기반의 학습은 물론이고 AlexNet,

GoogleNet 등의 다양한 CNN 학습 방법의 모델을 적용한 학습 모델을 생성하여 최적의 정확도를 갖는 모델 구축을 위한 연구 및 설계가 필요하다.

둘째, 기능 업데이트 부분이다. 제안 시스템은 이미지 및 영상에 대해 식별한 결과를 자동으로 출력할 수 있지만 이미지에서 물체의 위치를 탐색할 수 없다. 또한 2가지 이상의 하자가 복합적으로 발생하는 경우 이를 제대로 검출할 수 없다. 이 검색 기능을 설계 및 구축하기 위하여 CNN 기반으로 Multi-Label Classification을 기반으로 학습 모델을 구축하고, Object Detection과 Segmentation 등의 이미지 기반 딥러닝 기법을 기반으로 학습 모델을 생성하기 위한 연구 및 설계가 필요하다.



## 참 고 문 헌

1. 강태준, 2015, 시대별 공동주택 설계변천에 따른 하자유형 변화 및 특징에 관한 연구," 연세대학교 공학대학원, 서울
2. 강현욱, 박양호, 김용수, 2019, "공동주택에 대한 하자정보 관리시스템의 개선 모델" 한국건설관리학회 논문집 Vol.20(4) pp. 13-21.
3. 김도형, 이동윤, 이학주, 민윤기, 박인성, 조훈희, 2020, "공동주택 건축공사 하자유형별 중요도 분석", J. Korea Inst. Build. Constr. Vol. 20. No.4 : pp. 357-365
4. 김명호, 2019, "컴퓨터비전 기반 건설근로자 안전모 착용 여부 인식을 위한 딥러닝 기법의 적용", 국내석사학위논문 부경대학교 대학원, 2019. 부산
5. 김범수, 최은규, 이정훈, 송제영, 오상근(2017), "공동주택 욕실의 타일하자 발생 동향", 2017 대한건축학회 춘계학술발표대회논문집, vol.37(1), pp. 823~824
6. 김병현, 김건순, 진수민, 조수진, 2019, "영상기반 콘크리트 균열 탐지 딥러닝 모델의 유형별 성능 비교", 한국안전학회지, vol.34(6), pp. 50-57
7. 김진현, 고성석, 2012, "공동주택 마감공사의 하자위험도 평가에 관한 연구", 한국건설관리학회논문집 vol.13(6), pp. 63~70
8. 김진현, 2011, "공동주택 마감공사의 하자위험도 평가에 관한 연구" 국내석사학위논문 전남대학교 산업대학원, 2011. 광주
9. 권오성, 2013, "이미지 매칭과 모바일 증강현실을 활용한 건설 현장 하자관리 업무프로세스 개선 연구", 국내석사학위논문 中央大學校 大學院, 2013. 서울
10. 박지환, 정수완, 이서준, 송진우, 권순우, 2021, "스마트 디바이스 기반 유

지보수 관리자용자동화 모델 구축에 관한 연구”, 한국건설관리학회 논문집 vol.22(1), pp. 72-80

11. 박성준, 이창준, 한승현, 윤성민, 2018, “건설현장 육안안전점검의 인식관련 휴면에러 분석 연구”, 한국건설관리학회 정기학술발표대회 논문집, vol 19(1), pp. 181-182
12. 서덕석, 엄상권, 2007, “공동주택 하자소송의 발생형태 및 문제점에 관한 분석연구”, 한국생태환경건축학회 논문집, vol. 7(6), pp. 127-132.
13. 석성준, 유현경, 강경인, 2004, “공동주택 하자처리과정에 대한 거주자 입장의 만족도 분석”, 한국건축시공학회 학술발표대회 논문집, vol.4(2), pp. 91-94.
14. 송광, 2013, “신축공동주택 실내마감공사 하자 원인분석 및 예방방안 : 도배공사, 목질계 바닥재공사를 중심으로”, 중앙대학교 건축대학원, 서울
15. 신형준, 박일민, 1996, “건축물의 효율적인 하자관리시스템 구축에 관한 기초연구”, 공업기술연구소논문집, vol.10, pp. 13-23.
16. 신호현, 『도배통전』, 성안당(2009), p.130, ISBN 9788931562187 93540  
심영종, 진규남, 권석민, 서형종, 김예진, 2020, “AI 기반 건설기술 현황 및 연구전략”, 대전 : 한국토지주택공사 토지주택연구원
17. 안광훈, 윤창식, 천봉기, 김예상, 2002, “하자정보를 활용한 품질관리
18. 시스템개발에 관한 연구”, 대한건축학회논문집 구조계, vol.18(4), pp. 105-112.
19. 오세우, 김영석, 2005, “PDA 및 웹 기반의 공동주택 품질점검 및 하자관리 시스템의 개발”, 한국건설관리학회지, vol.6(1), pp. 140-150.
20. 오정환, 2009, “공동주택 하자관리 업무프로세스 개선.” 국내석사학위논문 崇實大學校 大學院, 2009. 서울
21. 이돈수, 2019, 공정별 하자관리 프로세스의 변경에 의한 공동주택의 하자

저감 방안, 국내박사학위논문 경기대학교 대학원, 2019, 서울

22. 이명규, 2014. "공동주택의 하자갈등 해소방안에 관한 연구" A Study on the conflict resolution method of Apartment House. *공공사회연구*, vol.4(1): pp. 160–187.
23. 이상효, 한만천, 김재준, 이정석, 2020, "공동주택 사용검사 전 하자 특성 분석", *Journal of the Korea Academia-Industrial cooperation Society*, vol.21(5), pp. 167–178, 2020.
24. 이호범, 김종우, 장일영, 2012, "이미지 분석기법을 이용한 콘크리트 구조물의 균열 검출 시스템 개발", *한국구조물진단유지관리공학회 논문집*, vol.16(1) pp. 64–77, 2012.
25. 이효찬, 박인학, 임태호, 문대철, 2020, "이미지 잡음에 강인한 CNN 기반 건물 인식 방법", *한국정보통신학회논문지*, vol.24(3), pp.341~348, 2020.
26. 이해린, 조동현, 박상현, 구교진, 2017, "하자예방정보 네서스 기반 건축마감공사 품질점검지원 모델", *한국건설관리학회 논문집*, vol.18(5), pp. 59–67, 2017.
27. 장호면, 2019, "효율적인 품질관리를 위한 공동주택 하자위험 분석", *Journal of the Korea Academia Industrial cooperation Society*, vol.20(11), pp. 510– 519
28. 전가현, 2019, "현장 시공품질 기반의 건설 기능인 숙련도 평가에 관한 적정성 검증 연구", *국내석사학위논문 연세대학교 대학원*, 2019. 서울
29. 정지범, 2015, "안전사각지대 발굴 및 효과적 관리 방안 연구", KIPA 연구보고서 2015-23, p.363
30. 주환섭, 2009, "아파트 주요 하자 요인의 시공단계 체크리스트에 관한 연구", *석사학위논문*, 창원대학교
31. 홍석일, 2010, "공동주택 마감공사에서의 하자예방을 위한 중점관리대상

도출.” 국내석사학위논문 서울시립대학교, 2010. 서울

32. 하의륜, 2017, “합성곱 신경망(CNN)기반 이미지 처리 시스템.” 국내박사 학위논문 배재대학교, 2017. 대전
33. 하희윤, 이훈구, 이윤선, 김재준, 2007, “하자보수보증금 기반의 하자 예방 관리에 관한 연구”, 대한건축학회논문집 구조계, vol.23(10), pp. 147–155.
34. Cha, Y. J., Choi, W., and Blylklztlrk, O., 2017, “Deep Learning-Based Crack Damage Detection Using Convolutional Neural Networks”, Computer-Aided Civil and Infrastructure Engineering, vol.32(5), pp. 361 – 378.
35. Chen X., Chang L. W., and Rodrigues C. I. et al., 2014, “Adaptive Cache Management for Energy Efficient GPU Computing”, Proceedings of the 47th annual IEEE/ACM international symposium on microarchitecture. IEEE Computer Society, pp. 343–355, 2014.
36. Gu. J., Wang. Z., Kuen. J., Ma. L., Shahroudy. A., Shuai. B., Liu. T., Wang X., Wang. L., Wang. G., Cai. J., and Chen. T., 2018, “Recent advances in convolutional neural networks,” Pattern Recognition, vol. 77, pp. 354–377, May. 2018.
37. Hasanzadeh, S., Esmaeili, B., and Dodd, M.D., 2017, “Impact of Construction Workers’ Hazard Identification Skills on Their Visual Attention.” Journal of Construction Engineering and Management, vol. 143(10), pp. 401–7070.
38. He. K, Zhang. X., Ren. S., and Sun, J., 2016, "Deep Residual Learning for Image Recognition," Proceeding of the IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, NV, USA, 2016, pp. 770–778.

39. Jeong, Y. H., 2016, "Improvement of Maintenance Bonds Including Defects before Inspection for Apartment Use", Master's Thesis, University of Seoul, Seoul, Korea, pp. 1-3, 2016.
40. Kim, B. S., Park, J. M., Choi, J. H., Seo, D. S., and Kim, O. K., 2011, "Comparative Analysis on Repairing Cost of Lawsuit on Concrete Crack Defect in Apartment Building", Korean Journal of Construction Engineering and Management, vol.12(6), pp. 142-150, Nov. 2011.
41. Lecun, Y., Bottou. L., Bengio. Y., and Haffner. P., 1998, "Gradient based learning applied to document recognition," Proceedings of the IEEE, vol.86(11), pp. 2278-2324, 1998.
42. See, J. E., Drury, C. G., Speed, A., Williams, A., and Khalandi, N., 2017, "The role of visual inspection in the 21st century.", Proceedings of the Human Factors and Ergonomics Society, pp. 262 - 266, 2017
43. Seo, D. S., Cho, K. R., 2008, "A Study on the Direction of Defect lawsuit Solutions on Apartment Buildings from Resident's Respect", Journal of Architectural Institute of Korea, vol.24(6), pp. 119-126
44. Sun, K., 2015, "Tagging and Classifying Facial Images in Cloud Environments Based on KNN using MapReduce." Dept. of Electrical and Electronic Engineering Major in Computer Science, 2015.
45. Son, Y. S., 2010, "Study on Defects before Completion of Mass Housing Defect Lawsuit Appraisal Categories", Master's Thesis, Kwangwoon University, Seoul, Korea, pp. 1-2, 2010.
46. Tong, Z., Gao, J., Han, Z., and Wang, Z., 2018, "Recognition of Asphalt Pavement Crack Length Using Deep Convolutional Neural Networks", Road Materials and Pavement Design, vol.19(6), pp. 1334 - 1349, 2018.

47. Yang, L., Li, B., Li, W., Liu, Z., Yang, G., and Xiao, J. (2017). “Deep Concrete Inspection Using Unmanned Aerial Vehicle Towards CSSC Database”, IEEE/RSJ International Conference on Intelligent Robots and Systems, 2017.
48. Zhang, A., Wang, K. C. P., Li, B., Yang, E., Dai, X., Peng, Y., and Chen, C., 2017, “Automated Pixel-Level Pavement Crack Detection on 3D Asphalt Surfaces Using a Deep-Learning Network”, Computer-Aided Civil and Infrastructure Engineering, 2017.



# **ABSTRACT**

## **Development of a Deep Learning Model to Classify Images of Wallpaper Defects in Apartment Building by Introducing Convolutional Neural Network**

**Jeon Hanra**

**Directed by Prof. Kim, Ju-Hyung**

**Department of Architectural, Civil and Landscape Engineering**

**Graduate School of Engineering**

**Hanyang University, Seoul, Korea**

Recently, many projects of redevelopment and reconstruction are being conducted actively, so it is being raised that prospective occupants of new apartment housing require high quality finishing materials compared to the past and quality of finishing materials which could meet a standard of the governments becomes important.

In addition, the number of cases of standard fragmentation and discerning defects on interior finishing construction is a growing trend. Currently, methods like a visual inspection are used to discern defects and those methods show huge limitations on reliability. The current thesis trend is to review prior research on defects, focusing on cracks and leaks on parts of structures related to the frame, and there is no research on

defect detection for internal finishing materials. Therefore, it is necessary to analyze working processes of existing defect detection and maintenance in order to improve credible defect detection. Based on the data, it is needed to conduct research to establish a reliable defect detection model for finishing materials by utilizing CNN algorithm.

Therefore, this study has a plan to cover a detection model for wallpaper defects, which takes place frequently among defections during finishing material constructions. For that, after directly collecting images of wallpaper defects from the new buildings site, this study conducted data augmentation by applying Augmentor in order to secure diversity and accuracy of the data. Based on the collected data, this study made the Resnet50 to be learned by dividing training and evaluation data sets to match four classification criteria of the wallpaper defect. In addition, it judged the suitability of the established system model by using error matrix, F-Score, and Accuracy. The results of this study show efficiency and reliability of the machine learning method compared to the existing visual inspection method.

Later, it is necessary to conduct research in order to simultaneously measure various defects in image data by establishing a learning model based on Multi-Label Classification.

## 연구 윤리 서약서

본인은 한양대학교 대학원생으로서 이 학위논문 작성 과정에서 다음과 같이 연구 윤리의 기본 원칙을 준수하였음을 서약합니다.

첫째, 지도교수의 지도를 받아 정직하고 엄정한 연구를 수행하여 학위논문을 작성한다.

둘째, 논문 작성시 위조, 변조, 표절 등 학문적 진실성을 훼손하는 어떤 연구 부정행위도 하지 않는다.

셋째, 논문 작성시 논문유사도 검증시스템 "카피킬러"등을 거쳐야 한다.

2022년11월30일

학위명 : 석사

학과 : 건축·토목·조경공학과

지도교수 : 김주형

성명 : 전한라



한 양 대 학 교 공 학 대 학 원 장 귀 하

## Declaration of Ethical Conduct in Research

I, as a graduate student of Hanyang University, hereby declare that I have abided by the following Code of Research Ethics while writing this dissertation thesis, during my degree program.

"First, I have strived to be honest in my conduct, to produce valid and reliable research conforming with the guidance of my thesis supervisor, and I affirm that my thesis contains honest, fair and reasonable conclusions based on my own careful research under the guidance of my thesis supervisor.

Second, I have not committed any acts that may discredit or damage the credibility of my research. These include, but are not limited to : falsification, distortion of research findings or plagiarism.

Third, I need to go through with Copykiller Program(Internet-based Plagiarism-prevention service) before submitting a thesis."

NOVEMBER 30, 2022

Degree : Master

Department : DEPARTMENT OF ARCHITECTURAL, CIVIL AND LANDSCAPE  
ENGINEERING

Thesis Supervisor : Kim, Ju-Hyung

Name : JEON HANRA

(Signature)